PARLO

Plano Mestre Técnico, Produto e Open Source

Intérprete de voz local, incremental, modular e open source

VERSÃO 12.3 · 1 de novembro de 2026

Documento mestre de produto, arquitetura, engenharia, qualidade, governação open source e lançamento.

Os valores não medidos estão identificados como metas ou hipóteses.

Como ler este documento

Esta versão 12.3 substitui a v12.2 como fonte principal de verdade do Parlo. Mantém a arquitetura, o roadmap por capacidades e a política de modelos, e corrige o que a auditoria técnica do repositório desmentiu. A alteração estrutural é a promoção da voz a parte própria do plano: a clonagem autorizada da voz da pessoa deixa de ser um capítulo dentro da síntese e passa a ser o eixo que ordena prioridades, gates e escolhas de modelo.

O documento separa três coisas que a versão anterior misturava em alguns pontos: o que está implementado e medido, o que está planeado com critérios de conclusão, e o que está em avaliação sem resultado. Uma capacidade descrita neste plano não é uma capacidade existente; o estado de cada uma está na secção 1, na matriz da secção 20 e no mapa de versões do Apêndice E.

A numeração é contínua de 1 a 82, agrupada em treze partes, sem títulos duplicados e sem capítulos órfãos. A Parte VI é a especificação do orquestrador de modelos e a Parte VII a da biblioteca modular, que mantém a aplicação leve enquanto o catálogo cresce. Cada parte pode ser lida isoladamente, mas as decisões das Partes XII e XIII prevalecem sobre descrições genéricas das partes anteriores.

Regra de evidência

> Uma afirmação só aparece como facto quando existe uma fonte oficial consultada ou uma medição feita nesta máquina, com método e condições descritas. Tudo o resto é candidato, hipótese ou valor por medir.

- **Verificado** significa que a fonte oficial (model card, repositório, licença) foi consultada e diz aquilo que o documento afirma.
- **Medido** significa que o número saiu de uma execução instrumentada, com hardware, versões, threads e quantização indicados junto.
- **Candidato** significa que o artefacto merece teste e ainda não ganhou o direito de ser default.
- **Por medir** significa que não pode ser anunciado como capacidade do Parlo, nem usado em notas de release.
- Licença do código do motor, licença dos pesos, licença das vozes e licença dos dados são sempre avaliadas em separado; nenhuma delas se herda das outras.
- Um scanner de licenças sem alertas prova que os metadados declarados estão coerentes. Não é aprovação jurídica.

O que muda na v12.3

- A voz passa a Parte II, com política Voice Clone First, Voice Profile, consentimento, compatibilidade entre motores e medição de identidade vocal.
- A matriz de modelos foi corrigida: Qwen3-TTS Base 0.6B e 1.7B são candidatos de clonagem; CustomVoice usa vozes predefinidas; VoiceDesign desenha voz; Chatterbox Multilingual PT-PT é candidato prioritário para português europeu e o checkpoint PT-BR é tratado à parte; Kokoro deixa de ser fallback PT-PT sem prova.
- Nenhum modelo é declarado vencedor sem teste interno. A tradução EN→PT fica explicitamente por resolver, com OPUS-MT e M2M100 418M como candidatos e critérios objetivos.
- A seleção de modelos deixa de usar regras simplistas de hardware e passa a depender de benchmarks internos, memória disponível, quantização, sistema operativo e latência.
- Acrescentam-se secções próprias para privacidade e dados biométricos, Regulamento Europeu da IA com o Artigo 50, segurança da cadeia de fornecimento e direitos de voz.
- O capítulo das licenças deixa de sugerir que a separação por processos resolve sozinha a questão GPL, e mantém Argos fora do núcleo enquanto a cadeia AGPL não estiver fechada.

- Roadmap e fases passam a ser definidos por dependências e critérios de conclusão, sem datas nem estimativas.
- A orquestração de modelos ganha especificação própria na Parte VI: PIMO, perfil de dispositivo, avaliação em três níveis, benchmarks por tarefa, seleção multicritério, composição de pipeline, monitorização com histerese, recuperação, ciclo de vida e protetor da identidade vocal.
- A biblioteca passa a ser uma camada independente na Parte VII: catálogo que evolui sem reinstalar a aplicação, compatibilidade entre versões, instalação e remoção por modelo, armazenamento com recursos partilhados, importação externa, distribuição assinada e ciclos de atualização separados.
- As decisões finais do autor ficam fixadas: objetivo de 100 MB para o instalador, catálogo em `parlo-models` com manifestos assinados em Ed25519, Piper e Argos fora do núcleo, corpus de avaliação original sob CC0-1.0, latência publicada em P50 e P95, e uma checklist interna de conformidade em vez de parecer jurídico.

Índice

PARTE I · FUNDAMENTOS

1. Estado do projeto e decisões executivas

2. Visão, público e família de produtos

3. Princípios não negociáveis

PARTE II · VOZ COMO CAPACIDADE CENTRAL

4. Política Voice Clone First

5. Voice Profile, consentimento e ciclo de vida

6. Compatibilidade de perfis entre motores

7. Identidade vocal entre idiomas

8. Síntese neutra, desenho de voz e conversão de voz

PARTE III · COMPORTAMENTO E PRODUTO

9. Streaming incremental e estados de texto

10. Parlo Dictate: escrever noutra língua

11. Experiência de utilização e regra transversal

12. Design system e superfícies

13. Acessibilidade, teclado e internacionalização

14. Fluxos completos e recuperação

PARTE IV · MODELOS

15. Estratégia de modelos e regra de evidência

16. Reconhecimento de fala

17. Tradução

18. Clonagem e síntese de voz

19. Diarização, VAD e alinhamento

20. Matriz de modelos por função

PARTE V · LICENÇAS E DIREITOS

21. Licenciamento por artefacto

22. Dependências e risco copyleft

23. Pesos, vozes e datasets

24. Modelos bloqueados e catálogo experimental

25. Direitos de voz e uso aceitável

26. Conformidade automática em cada release

PARTE VI · ORQUESTRAÇÃO INTELIGENTE, MODEL HUB E AUTO SELECT

27. Arquitetura de orquestração: PIMO e fronteiras

28. Manifesto por modelo e níveis de evidência

29. Descoberta e filtragem eliminatória

30. Perfil automático do dispositivo

31. Avaliação em três níveis

32. Benchmarks com evidência por tarefa

33. Seleção multicritério

34. Composição de pipeline

35. Monitorização de runtime e adaptação

36. Fallback e proteção da identidade vocal

37. Model Hub e ciclo de vida

38. Cache de resultados e reutilização

39. Privacidade e segurança da orquestração

40. Experiência do utilizador e transparência

41. Testes automáticos da orquestração

42. Critérios de aceitação do PIMO

43. Fases de implementação do PIMO

PARTE VII · BIBLIOTECA MODULAR DE MODELOS

44. Duas camadas: aplicação e biblioteca

45. Contratos entre aplicação, biblioteca e runtimes

46. Catálogo evolutivo e descoberta de novidades

47. Compatibilidade entre versões

48. Instalar, remover e substituir

49. Otimização de armazenamento e recursos partilhados

50. Biblioteca curada e personalizada

51. Avaliação de novidades pelo PIMO

52. Importação de modelos externos

53. Distribuição segura e atualizações atómicas

54. Ciclos de atualização independentes

55. Dois modos de utilizador

PARTE VIII · ARQUITETURA E PLATAFORMA

56. Camadas, núcleo e isolamento

57. Protocolo entre núcleo e motores

58. Pipeline de áudio, latência e adaptação

59. Hardware, backends e perfis

60. Extensibilidade: CLI, API, SDK e plugins

PARTE IX · PRIVACIDADE, SEGURANÇA E LEGISLAÇÃO

61. Privacidade local-first

62. Dados pessoais e biométricos

63. Regulamento Europeu da IA e Artigo 50

64. Segurança e cadeia de fornecimento

65. Reuniões: consentimento e contexto

PARTE X · REUNIÕES

66. Parlo Meeting: Lite, Live e Chat

PARTE XI · QUALIDADE, ROADMAP E FASES

67. Lições de Handy, VoiceStudio e Wispr Flow

68. Roadmap incremental

69. Fases de execução e critérios de conclusão

70. Definição de concluída e regras de corte

71. Barra competitiva

PARTE XII · OPEN SOURCE, DISTRIBUIÇÃO E GOVERNANÇA

72. Repositório e ficheiros obrigatórios

73. Licença do código, DCO e contribuições

74. Releases, artefactos e avisos

75. Transparência na aplicação

76. Governação

PARTE XIII · DECISÕES E RISCOS

77. Decisões fechadas

78. Decisões que o Parlo toma automaticamente

79. Decisões pendentes de teste interno

80. Questões que exigem decisão humana ou validação jurídica

81. Riscos por severidade

82. Checklist final antes da primeira release

APÊNDICES

A. Factos por componente

B. Glossário operacional

C. Fontes primárias

D. Registo de alterações da v12.3

E. Mapa das versões

F. Regra permanente para o agente de desenvolvimento

PARTE I · FUNDAMENTOS

1. Estado do projeto e decisões executivas

O Parlo tem hoje um núcleo funcional pequeno e verificável: reconhecimento local, tradução local e síntese opcional, ligados por um protocolo local, mais uma aplicação de janela própria. Tem também uma política de licenciamento implementada e automatizada. Não tem clonagem de voz, não tem Model Hub, não tem seleção automática e não tem a tradução EN→PT resolvida. Esta secção diz exatamente onde está cada coisa, porque um plano que confunde protótipo com produto leva a decisões erradas nas partes seguintes.

1.1. Estado verificado nesta revisão

Área	Estado	Evidência
Última tag publicada	v0.1.6	`git tag` no repositório; o CHANGELOG tem entradas até 0.1.7
Motor de cascata	Implementado	`engines/cascade` reconhece, traduz e sintetiza por blocos, em CPU
Reconhecimento	Implementado e medido	Parakeet TDT v3 int8 por sherpa-onnx e Whisper por faster-whisper
Estados de texto	Implementado	Parcial, estável, final e corrigido; sessão fecha após 0,45 s de silêncio
Tradução	Implementada com dependência em revisão	Argos Translate no caminho publicado, com MiniSBD AGPL transitivo
Tradução OPUS-MT	Implementada em laboratório, não publicada	PT→EN correto; EN→PT degenera nos dois checkpoints testados
Síntese	Opcional e externa	Adaptador Piper separado, GPL-3.0-or-later, fora do programa do motor
Clonagem de voz	Não existe	Sem Voice Profile, sem consentimento, sem motor de clonagem
Model Hub e Auto Select	Não existem	Existe catálogo de licenças e painel de download, sem seleção automática
Diarização e Meeting	Não existem	Sem código, sem captura multifonte
Licenciamento	Implementado	Apache-2.0 no código original, MIT preservado para releases antigas, avisos e SBOM gerados
Gate de licenças	Implementado	`tools/licenses.py` lê a cadeia Rust, a cadeia Python e o catálogo de modelos

1.2. Números medidos, com condições

Medição	Valor	Condições
Primeiro parcial PT-PT	849 ms	Parakeet TDT v3 int8, 4 threads, CPU, 20 frases
Texto final PT-PT	3,36 s	Mesma execução, após fecho do segmento
Frases confirmadas antes do fecho	81%	Mesma execução
WER final PT-PT	0,231 Parakeet · 0,279 Whisper base	Corpus PT-PT de 20 frases, voz Piper europeia
Tradução PT→EN por OPUS-MT	69 a 130 ms por frase	CTranslate2 int8, 4 threads, beam 4, penalização de repetição
Cobertura de licenças	523 componentes, zero problemas	`tools/licenses.py check --verify-installed`

Estes números não são promessas de produto. São o ponto de partida dos gates da secção 32 e mudam quando o corpus, o modelo ou o hardware mudarem.

1.3. Decisões executivas

Tema	Decisão
Experiência principal	Falar na própria voz e ouvir a tradução na própria voz, quando o hardware e um motor aprovado o permitirem
Voz neutra	Existe como fallback explícito, teste de integridade e escolha consciente; nunca substitui a voz da pessoa em silêncio
Escolha de modelos	O Parlo decide; o utilizador vê Automático. A escolha manual é override avançado
Tradução	NMT por par com checkpoint aprovado; nenhum par é declarado suportado sem avaliação interna
Licença do código	Apache-2.0 para o código original; MIT preservado nas releases antigas
Componentes externos	Piper, Argos e qualquer runtime copyleft ficam fora do núcleo e fora dos arquivos de release
Pesos e vozes	Descarregados à parte, nunca incluídos no instalador, cada um com a sua licença registada
Contribuições	DCO, sem transferência de direitos, com regra de proveniência
Plataforma inicial	Windows primeiro; macOS e Linux por marcos próprios
Privacidade	Áudio, perfis, transcrições e traduções ficam no dispositivo; nenhuma telemetria obrigatória

Regra de leitura do estado: enquanto a secção 79 tiver itens abertos, o Parlo não anuncia a capacidade correspondente. Uma capacidade em avaliação não aparece no README, nas notas de release nem na interface como se existisse.

2. Visão, público e família de produtos

Visão. Uma pessoa fala na sua língua, com a sua voz, e é ouvida na língua do interlocutor, sem que o áudio saia do computador. O Parlo não substitui intérpretes profissionais; retira a barreira técnica e a dependência de serviços exteriores nos casos em que uma pessoa precisa de continuar a falar como ela própria.

A voz é parte do argumento, não um detalhe de acabamento. Uma tradução falada numa voz genérica faz o interlocutor ouvir outra pessoa. O Parlo persegue a identidade vocal autorizada e diz com clareza quando não a consegue garantir.

2.1. Público

Público	Necessidade	Superfície
Profissionais que trabalham em língua estrangeira	Escrever e falar com correção sem perder tempo	Dictate e Traduzir seleção
Equipas internacionais em chamadas	Acompanhar e intervir na própria voz	Captions e Live
Pessoas com perda auditiva ou em ambientes ruidosos	Legendas fiáveis e legíveis	Captions
Utilizadores com requisitos de privacidade	Nada sai da máquina	Todos os modos, por defeito
Criadores de conteúdo	Dobrar conteúdo autorizado na própria voz	Dub
Programadores e integradores	Contratos estáveis, CLI e API	CLI, API local, SDK

2.2. Família de produtos sobre o mesmo núcleo

Produto	Utilidade	Estado
Parlo Dictate	Ditado local com escrita noutra língua	Parcial: motor e CLI existem, experiência de overlay por fechar
Parlo Captions	Legendas do microfone e do áudio do sistema	Parcial: existe modo de legendas na cascata, sem captura de sistema
Parlo Voice	Leitura de texto e de traduções	Parcial: Piper externo opcional; clonagem não existe
Parlo Live	Interpretação bidirecional falada	Planeado
Parlo Meeting	Reuniões com transcrição e chat	Planeado
Parlo Dub	Dobragem de conteúdo autorizado	Experimental, fora do caminho crítico
Parlo CLI e API	Integração local	CLI implementada; API local estável planeada

Posicionamento honesto. O Parlo compete com ferramentas de ditado e gestores de modelos, não com serviços de interpretação simultânea. O que pode ser genuinamente melhor é a combinação de voz própria, execução local, gestão de modelos sem escolha técnica e transparência de licenças. Nenhuma dessas vantagens está demonstrada enquanto não houver produto e medições públicas.

3. Princípios não negociáveis

- **Local por defeito.** Nenhuma chamada de rede durante uma sessão local, incluindo telemetria, analytics ou atualização silenciosa. A verificação de atualizações é a única chamada permitida, e não transporta áudio, identificadores ou conteúdo.
- **Voz da pessoa primeiro.** O caminho principal tenta clonagem autorizada antes de qualquer voz neutra. A degradação para voz genérica é explícita e visível.
- **Incremental por desenho.** O sistema processa áudio enquanto a pessoa fala e expõe texto provisório e estável, sem esperar pelo fim da frase.
- **Não inventar simultaneidade.** Se um modelo só funciona por blocos, a interface diz isso e não vende streaming que não existe.
- **Sem bloqueio de fornecedor.** Modelos e runtimes são substituíveis por adaptadores com contrato versionado.
- **Sem licença escondida.** A licença de cada artefacto aparece antes do download e antes da ativação.
- **Qualidade honesta.** Latência, precisão, memória e compatibilidade são publicadas com hardware, versões e método.
- **Degradação graciosa.** Se a voz falhar, mantêm-se legendas e texto; nunca se perde o que a pessoa disse.
- **Consentimento verificável.** Nenhum perfil de voz nasce sem declaração explícita de autorização, e todos podem ser apagados por completo.
- **Código e pesos são artefactos distintos.** Uma licença permissiva no código nunca se estende automaticamente a um checkpoint, a uma voz ou a um dataset.

PARTE II · VOZ COMO CAPACIDADE CENTRAL

4. Política Voice Clone First

A síntese deixou de ser um módulo de leitura em voz alta para se tornar o centro do produto. Esta política define o que o Parlo tenta primeiro, o que faz quando não consegue, e o que diz ao utilizador.

4.1. Ordem de tentativa

Ordem	Caminho	Quando é usado	O que o utilizador vê
1	Clonagem autorizada com o perfil do falante	Existe Voice Profile consentido e um motor aprovado para o par de línguas e o hardware	«A falar na tua voz»
2	Clonagem autorizada com outro motor aprovado	O motor preferido falhou, excedeu memória ou não cobre o idioma	«A falar na tua voz com outro motor»
3	Voz neutra aprovada para o locale	Nenhum clonador aprovado serve a combinação	«A falar com uma voz neutra, porque a tua voz não está disponível neste idioma»
4	Só texto e legendas	Síntese indisponível ou desativada	«Sem voz: mostro o texto traduzido»

A ordem é aplicada pelo Auto Select, não pelo utilizador. A troca nunca é silenciosa: os estados 3 e 4 exigem aviso visível e registo no histórico da sessão.

4.2. O que a política proíbe

- Substituir a voz da pessoa por uma voz genérica sem o dizer, mesmo quando a qualidade sobe.
- Anunciar «voz preservada» quando o motor mudou e a identidade não foi medida nesse motor.
- Prometer clonagem em tempo real em hardware onde não foi medida.
- Clonar voz de terceiros sem autorização declarada, ou manter perfis de voz de terceiros pré-instalados.
- Usar amostras de voz para treino, telemetria ou melhoria de modelos. Não existe recolha de dados para treino.

4.3. Consequências para o resto do plano

- A matriz de modelos da secção 20 distingue quem clona, quem só sintetiza e quem desenha voz.
- O Model Hub da secção 37 tem a clonagem como tarefa de primeira classe, com requisitos de memória e latência próprios.
- O gate de qualidade da secção 32 inclui identidade vocal, não apenas inteligibilidade.
- A interface da secção 11 distingue três estados de voz e nunca os confunde.

5. Voice Profile, consentimento e ciclo de vida

Um Voice Profile é um recurso local que representa a voz de uma pessoa autorizada. Não é um ficheiro solto no disco: tem identidade, finalidade, consentimento, artefactos derivados e uma operação de eliminação que remove tudo.

5.1. Criação

Passo	O que acontece	Regra
1. Escolha do método	Gravar agora ou importar áudio	Importação exige declaração de autorização sobre o ficheiro
2. Recolha	10 a 30 s de fala contínua, ou mais quando o motor exigir	O produto indica o mínimo do motor escolhido, não um número universal
3. Controlo de qualidade	Nível, ruído de fundo, eco, presença de uma só voz, fala suficiente	Rejeita ou pede nova amostra com uma razão concreta
4. Texto de referência	Transcrição automática da amostra, corrigível	Obrigatório quando o motor precisa de texto alinhado
5. Consentimento	Declaração explícita com finalidade e âmbito	Sem consentimento não há perfil
6. Pré-visualização	Frase curta sintetizada com o perfil	O utilizador ouve antes de ativar
7. Ativação	Perfil guardado e disponível para os motores compatíveis	Nome, idioma de referência e data visíveis

5.2. Registo de consentimento

O registo é local e contém, no mínimo: identificador do perfil; declaração de que a voz é do próprio ou de pessoa que autorizou; finalidade (ditado, legendas, reuniões, dobragem); versão do texto de informação apresentado; data e hora; e o âmbito autorizado. Não se inventa verificação de identidade que o projeto não consegue garantir: o Parlo registra uma declaração, não certifica uma pessoa.

5.3. Proteção e armazenamento

- Amostras, embeddings, prompts de voz e cache vivem numa pasta de dados do utilizador, fora do repositório e fora dos arquivos de release.
- Encriptação opcional com chave do sistema operativo (DPAPI no Windows, Keychain no macOS, Secret Service no Linux), ativada por pedido do utilizador e documentada.
- Nada é enviado para fora da máquina, nem para verificação, nem para melhoria de qualidade.
- Perfis de terceiros pré-instalados não existem, em nenhuma circunstância.

5.4. Eliminação

A eliminação de um perfil remove amostra de referência, transcrição de referência, embeddings, prompts, caches, previews e registos de consentimento associados, e invalida qualquer cache de síntese que dependa dele. A operação termina com uma confirmação que lista o que foi apagado. Exportar e importar perfis é permitido, mas o ficheiro exportado é marcado como sensível e não é incluído em cópias automáticas.

6. Compatibilidade de perfis entre motores

Um perfil criado para um motor não é um perfil universal. Motores diferentes usam representações diferentes: alguns guardam embeddings, outros precisam de áudio de referência com transcrição, outros de um prompt acústico com duração fixa. Assumir compatibilidade é a forma mais rápida de quebrar a promessa de identidade vocal.

6.1. Modelo de dados

Camada	Conteúdo	Partilhada?
Identidade	Nome, idioma de referência, consentimento, data	Sim, entre motores
Amostra de referência	Áudio autorizado e transcrição corrigida	Sim, se o utilizador autorizar a sua preservação
Representação por motor	Embedding, prompt ou cache específico do motor e da versão	Não: é derivada e versionada
Cache de síntese	Áudio gerado, por texto e motor	Não: descartável

6.2. Regras de mudança de motor

- O Parlo verifica se existe representação válida para o motor de destino. Se existir, usa-a; se não, deriva-a a partir da amostra de referência.
- Se a amostra de referência foi apagada por opção do utilizador, a derivação é impossível. O Parlo diz isso antes da troca, não depois, e oferece uma de duas saídas: manter o motor atual ou criar um novo perfil com nova gravação.
- Mudar de motor não autoriza anunciar a mesma qualidade. A identidade vocal do novo motor só é afirmada depois de medida segundo a secção 7.
- Cada representação guarda o identificador e a versão do motor que a produziu. Uma atualização de motor que invalide a representação é tratada como incompatibilidade, não como erro genérico.

7. Identidade vocal entre idiomas

Preservar a voz entre idiomas não significa preservar o sotaque. O objetivo é manter o timbre, a qualidade da voz e traços prosódicos reconhecíveis, aceitando que a pronúncia de uma língua estrangeira pode ser marcada pela língua de origem. A interface deve dizer isto de forma simples, porque é a expectativa mais comum e a mais fácil de desiludir.

7.1. O que é medido

Dimensão	Método	Uso
Semelhança de identidade	Similaridade de embedding de locutor entre referência e saída	Gate interno de clonagem
Inteligibilidade	Taxa de erro de reconhecimento da saída sintetizada	Gate de utilidade
Naturalidade	Avaliação cega por ouvintes, escala curta	Gate de qualidade percebida
Estabilidade	Variação entre frases e ao longo de sessões longas	Gate de sessões prolongadas
Latência	Tempo até ao primeiro áudio sintetizado	Gate de modo quase-tempo-real
Cobertura por idioma	Resultado por par de línguas e variante	Decisão do Auto Select

Os limiares numéricos são internos e publicados apenas com o método e o hardware ao lado. Um valor sem condições não entra em notas de release.

7.2. Limites assumidos

- A identidade mantém-se tanto melhor quanto mais próxima for a língua de destino da língua da amostra. Pares distantes exigem amostras maiores e produzem resultados mais frágeis.
- Nenhum motor é declarado bom em todos os pares. O estado é por combinação: motor, par de línguas, variante regional e hardware.
- Sotaque, ritmo e hesitações não são reproduzidos por igual em todos os motores; alguns normalizam a prosódia e perdem espontaneidade.
- Em hardware modesto, a clonagem pode não cumprir o orçamento de latência. Nesse caso aplica-se a secção 4.1, sem promessas.

8. Síntese neutra, desenho de voz e conversão de voz

Três funcionalidades vizinhas da clonagem, com papéis diferentes e sem se confundirem com ela.

Capacidade	O que é	Papel no produto	Regra
Síntese neutra	Voz genérica de catálogo, sem identidade do utilizador	Fallback, leitura de texto, verificação de integridade do pipeline	Sempre identificada como voz neutra
Desenho de voz	Geração de uma voz a partir de uma descrição, sem amostra de uma pessoa	Criação de vozes para conteúdo próprio, testes, acessibilidade	Não é clonagem; não usa perfil de pessoa real
Conversão de voz	Transformação de áudio existente para outra identidade vocal	Só quando trouxer vantagem medida sobre a síntese com clonagem	Exige autorização sobre a voz de destino e sobre o áudio
Clonagem	Síntese com a identidade de uma pessoa autorizada	Caminho principal	Consentimento obrigatório

A conversão de voz acrescenta uma etapa ao pipeline, aumenta a latência, potencia artefactos e cria uma superfície adicional de direitos. Fica fora do caminho crítico e só entra se a comparação interna mostrar vantagem clara em qualidade ou em custo, com a mesma autorização exigida para clonagem.

A voz neutra continua a ter função: valida a saúde do pipeline quando a clonagem falha, serve quem não quer clonar, e permite ouvir uma tradução em minutos numa máquina onde nenhum clonador cumpre o orçamento. Nunca é o resultado por defeito quando existe perfil válido.

PARTE III · COMPORTAMENTO E PRODUTO

9. Streaming incremental e estados de texto

O Parlo começa a capturar e a processar áudio quando deteta fala. Não espera pelo fim da frase para iniciar reconhecimento, tradução ou preparação de síntese. O resultado pode ser provisório e ser corrigido antes de ficar confirmado.

9.1. Estados de texto

Estado	Significado	Comportamento na interface
Parcial	Hipótese atual do reconhecedor; pode mudar com novo áudio	Estilo visual distinto; nunca é colado como final
Estável	Confirmado por consenso temporal entre hipóteses	Pode ser traduzido e preparado para emissão
Final	Segmento fechado por pausa, fronteira semântica ou decisão do utilizador	Persiste na transcrição e fecha a tradução
Corrigido	Texto provisório que mudou	Atualiza o texto e, se ainda não emitido, a tradução
Emissão bloqueada	Contexto insuficiente ou confiança baixa	Espera mais áudio; não inventa palavras

9.2. Ciclo incremental

- Captura contínua em blocos pequenos, com timestamps monotónicos e identificador de sessão.
- Deteção de atividade de voz sem usar o silêncio como condição obrigatória para iniciar inferência.
- Reconhecimento com estado reaproveitado quando o motor o permite; reprocessamento com sobreposição quando não permite.
- Janela de contexto deslizante e região de texto provisório com estabilização por consenso entre as duas últimas hipóteses.
- Tradução apenas de segmentos suficientemente estáveis, com contexto anterior, glossário e nomes próprios.
- Síntese preparada por unidades semânticas curtas, emitida quando a probabilidade de revisão for baixa.
- Fecho do segmento por pausa, pontuação, limite de contexto ou comando, sem perder o contexto da sessão.

9.3. Políticas de streaming

Política	Vantagem	Custo
Streaming nativo do modelo	Evita recalcular a janela toda	Depende de suporte real do motor
Local agreement	Confirma prefixo comum entre hipóteses	Atrasa a confirmação
Alinhamento por atenção	Decide com base em evidência acústica	Não é universal entre modelos
Janela deslizante com sobreposição	Simples e aplicável a qualquer modelo	Gasta CPU e pode repetir texto

O modo atual do motor é reportado como reprocessamento, e não como streaming nativo, porque é isso que a implementação faz. Uma capacidade futura de streaming nativo passa a ser declarada quando existir, com medição própria.

9.4. Emissão de voz

Transcrever continuamente não é o mesmo que falar cada palavra reconhecida. Se a síntese emitir cedo demais, pode dizer algo que a frase seguinte desmente. O Parlo mostra texto parcial de imediato, traduz quando há contexto suficiente e usa um atraso de emissão ajustável. Em conversa, uma pequena espera inteligente é melhor do que falar depressa e dizer disparates.

10. Parlo Dictate: escrever noutra língua

Caso de uso que motiva a funcionalidade: «preciso de escrever um e-mail em alemão, mas sou português». O utilizador escolhe a língua de escrita, carrega no atalho e fala em português; o Parlo escreve no campo ativo o texto em alemão.

10.1. Dois idiomas independentes

Conceito	Regra
Idioma falado	Definido no onboarding, é o idioma do reconhecimento; deteção automática opcional
Idioma de escrita	Escolhido a cada utilização, com favoritos para troca em um clique
Variante	PT-PT e PT-BR na origem; EN-GB, EN-US, ES-ES, ES-LatAm, DE-DE, DE-AT, DE-CH no destino, quando o motor as distinguir
Registo	Formal, neutro ou informal, com predefinição por língua e por aplicação
Estilo	Verbatim, limpo, traduzido fiel ou traduzido profissional

10.2. Barra flutuante

Uma barra compacta junto à parte inferior do ecrã, sem roubar o foco da aplicação de destino, porque o overlay com foco impede a colagem no campo ativo.

```
● A ouvir… [ PT-PT → Deutsch ] [ Formal ] 00:07

Original: Boa tarde, Sr. Müller. Venho confirmar a reunião de quinta…

Escrita: Guten Tag, Herr Müller. Ich möchte das Treffen am Donnerstag …

Enter inserir · Esc cancelar · Tab formal/informal · Alt+L trocar língua
```

O chip mostra origem e destino. O texto parcial aparece na língua falada. Ao largar a tecla, a barra mostra que está a traduzir e depois o texto final. Rever antes de inserir é a predefinição nas primeiras utilizações e em pares ainda não validados; inserir automaticamente pode ser ativado por par de línguas.

10.3. Garantias de fidelidade

- Retro-tradução opcional na pré-visualização, que expõe erros grosseiros sem provar correção.
- Verificador determinístico de números, datas, valores, e-mails, URLs e nomes próprios, com alerta quando algo desaparece ou muda.
- Sinalização de negações em falta, que é o erro mais perigoso num e-mail profissional.
- Glossário e lista de «não traduzir» para nomes, marcas, siglas e termos técnicos.
- Nível de confiança por par e motor, visível na barra: validado, candidato ou experimental.
- Aviso de pivô quando a tradução passa por inglês.
- Falha nunca silenciosa: se a tradução vier vazia ou truncada, a barra diz isso e oferece inserir o original.

10.4. Níveis de suporte por par

Nível	Pares	Condição para subir
Validado	Nenhum ainda	Avaliação humana cega, corpus de e-mails e mensagens, sessão de 30 minutos sem degradação, licença fechada
Candidato prioritário	PT↔EN	Modelo aprovado por par, avaliação por falante nativo, corpus próprio
Candidato	PT→DE, PT→ES, PT→FR e inversos	Existência de modelo direto aceitável e os mesmos critérios
Experimental	Qualquer par via pivô inglês	Sempre assinalado e desligado por defeito

Nenhum par é anunciado como suportado porque um checkpoint lista o idioma. O estado de PT↔EN está descrito na secção 17 e continua dividido: PT→EN tem um caminho medido, EN→PT não tem.

11. Experiência de utilização e regra transversal

O Parlo privilegia a ação mais provável no contexto e esconde a complexidade até ser necessária. O utilizador não deve abrir a janela principal para ditar, traduzir, ver o estado de uma sessão ou marcar um momento. A janela principal é o centro de configuração e gestão; as ações frequentes acontecem em overlays compactos, atalhos e controlos junto ao contexto.

11.1. Elementos da janela principal

Elemento	Comportamento
Estado	A ouvir, a reconhecer, a traduzir, a falar, atrasado, offline ou erro, com a razão em palavras simples
Voz	Estado da voz em uso: clonada autorizada, neutra ou indisponível, sempre nomeado
Transcrição	Texto parcial em estilo distinto, texto confirmado legível
Tradução	Versão provisória e confirmada, ocultável
Motor	Nome e versão do motor de reconhecimento, tradução e voz, e o que o Auto Select escolheu
Privacidade	Pausa, silenciar microfone, terminar sessão, apagar transcrição, estado de captura sempre visível
Fallback	Alternar para legendas ou voz neutra sem perder a sessão

11.2. Primeira execução

- Explicar em linguagem simples o que é processado localmente e que permissões são necessárias.
- Perguntar o idioma falado e os idiomas de escrita favoritos.
- Detetar hardware e apresentar duas recomendações: equilibrado e mais leve.
- Mostrar o conjunto de modelos e os tamanhos antes de descarregar.
- Oferecer a criação de Voice Profile como passo opcional, com consentimento, nunca como condição de uso.
- Testar microfone, idioma e latência com uma frase de demonstração, e no Dictate ditar uma frase e vê-la traduzida.
- Guiar a configuração do microfone virtual por aplicação, sem instalar drivers sem consentimento.

11.3. Preferências sem sobrecarga

Preferências agrupadas por tarefa, com valores por omissão que funcionam sem serem tocados. O utilizador avançado consegue escolher motor e quantização; o utilizador normal nunca é obrigado a ver essa lista para ditar uma frase. Alterar um default do Auto Select é um override explícito, com aviso de que o Parlo deixa de escolher por si.

12. Design system e superfícies

Superfície	Função	Regra
Overlay de ditado	Falar e inserir texto junto ao cursor	Nunca rouba o foco; fecha com Esc
Barra de legendas	Ler o que está a ser dito	Tamanho, contraste e posição configuráveis
Janela principal	Configuração, histórico, modelos, licenças	Navegação por tarefas, sem painel técnico permanente
Janela de reunião	Estado, captura, pausa e transcrição	Compacta por omissão, expansível
Área de licenças	Transparência de componentes e modelos	Acessível em dois cliques a partir da janela principal

Regras visuais: um só acento de cor por ecrã; estados com texto além de cor; animação apenas para indicar mudança de estado; nenhum elemento decorativo que consuma atenção durante uma chamada. A interface é em inglês, com preparação para tradução dos textos da própria aplicação.

13. Acessibilidade, teclado e internacionalização

- Toda a funcionalidade essencial é alcançável só com teclado, com foco visível e ordem lógica.
- Legendas e transcrições com tamanho de letra, contraste e espaçamento configuráveis, incluindo modo de alto contraste.
- Compatibilidade com leitores de ecrã nos fluxos principais: iniciar, parar, ler estado, inserir texto.
- Nenhuma informação transmitida apenas por cor ou apenas por som.
- Atalhos globais configuráveis, push-to-talk e modo mãos-livres, sem atalhos que colidam com os do sistema.
- Idioma da interface independente do idioma falado e do idioma de escrita.
- Diagnóstico de microfone que não exige enviar gravações para lado nenhum.

Acessibilidade é requisito de lançamento, não trabalho posterior: uma release que quebre a navegação por teclado nos fluxos principais não passa o gate da secção 70.

14. Fluxos completos e recuperação

Fluxo	Passos	Falha prevista	Recuperação
Primeiro ditado	Instalar, escolher idioma, falar, inserir	Modelo ausente	O Parlo mostra o tamanho, descarrega e retoma
Ditado traduzido	Escolher destino, falar, pré-visualizar, inserir	Tradução vazia	Oferece original e nova tentativa
Criar Voice Profile	Gravar, validar, consentir, ouvir, ativar	Amostra ruidosa	Pede nova amostra com a razão concreta
Ouvir na própria voz	Escolher perfil, traduzir, sintetizar	Identidade não medida para o idioma	Avisa e oferece voz neutra identificada
Legendas de reunião	Ativar, transcrever, exportar	Áudio do sistema indisponível	Continua só com microfone e diz o que falta
Atualização	Verificar, ler notas, instalar	Falha de assinatura	Aborta e mantém a versão anterior
Apagar tudo	Escolher âmbito, confirmar	—	Lista o que foi apagado

Regra transversal de recuperação: nenhuma falha de motor, modelo ou dispositivo pode perder texto, áudio já reconhecido ou um perfil consentido. O produto degrada em capacidades, nunca em dados do utilizador.

PARTE IV · MODELOS

15. Estratégia de modelos e regra de evidência

Não existe um único melhor modelo para todas as etapas. O Parlo escolhe o modelo elegível por tarefa, idioma, variante, hardware, latência, qualidade e direitos de utilização. A comparação é trabalho interno; o utilizador recebe uma decisão e uma explicação curta.

O que a auditoria obriga a corrigir na versão anterior:

- Nenhum modelo é declarado vencedor por leitura de model card. Um modelo só se torna default depois de passar os gates da secção 32.
- Nenhuma regra simplista do tipo «quatro núcleos e 8 GB de RAM equivale ao modelo X» entra no produto. A seleção usa memória disponível, quantização, sistema operativo, backend, latência medida e qualidade medida.
- Candidato e recomendado são estados diferentes. Misturá-los foi o erro que colocou na matriz anterior um modelo de clonagem a passar por modelo de vozes predefinidas.

15.1. Regra de decisão por tarefa

Tarefa	O que decide	O que nunca decide
Reconhecimento	Idioma e variante, duração da fala, memória, latência, qualidade medida	Popularidade do modelo
Tradução	Par de línguas, licença do checkpoint, fidelidade medida	Tamanho do modelo
Clonagem	Identidade vocal medida, latência, memória, cobertura do par de línguas	Rótulo «multilingual» no cartão
Síntese neutra	Locale, naturalidade, custo, licença da voz	Semelhança com uma pessoa
Diarização	Número de falantes, ruído, duração	Universalidade do modelo

16. Reconhecimento de fala

Modelo	Versão analisada	Licença do código e dos pesos	PT-PT	Papel
Parakeet TDT 0.6B v3	checkpoint v3, int8 por sherpa-onnx	Pesos CC-BY-4.0; runtime Apache-2.0	Sim, entre 25 línguas europeias	Candidato principal para reconhecimento por blocos em CPU
Whisper large-v3-turbo, medium, small, base	via faster-whisper e CTranslate2	MIT no código e nos pesos; CTranslate2 MIT	Sim	Candidato de compatibilidade ampla e alta robustez
Qwen3-ASR 0.6B	checkpoint Apache-2.0	Apache-2.0	Cobertura PT na família; variante PT-PT por confirmar no checkpoint	Experimental até integração e gate de recursos
Nemotron 3.5 ASR 0.6B	cartão NVIDIA	Licença e runtime a verificar por versão	pt-PT indicado em fonte secundária	Pista experimental, não desktop

O reconhecimento em produção hoje é Parakeet por omissão e Whisper como alternativa, ambos em CPU, com WER medido de 0,231 e 0,279 no corpus PT-PT de 20 frases. Qwen3-ASR permanece no catálogo como candidato experimental, com licença verificada e sem direito a default.

Regras de seleção. O Auto Select considera o idioma e a variante, o comprimento esperado da fala, a memória disponível, a latência medida no perfil de hardware, e a qualidade medida no corpus mais próximo. Um modelo com melhor WER médio mas latência incompatível com legendas em direto não é recomendado para esse

modo.

17. Tradução

A tradução é a área com maior dívida técnica do projeto. A conclusão anterior de que a substituição do Argos estava resolvida não se sustenta: o caminho foi implementado e medido, mas só metade dos pares funciona.

17.1. Estado por caminho

Caminho	Estado	Factos
Argos Translate 1.11.0	No código publicado, em revisão	Declara MIT, mas depende de MiniSBD, que declara AGPLv3, e o código importa-a diretamente
OPUS-MT PT→EN (`opus-mt-ROMANCE-en`)	Medido, não publicado	Apache-2.0; 69 a 130 ms por frase em CTranslate2 int8; 3 de 3 amostras corretas
OPUS-MT EN→PT (`opus-mt-tc-big-en-pt`, `opus-mt-en-ROMANCE`)	Falhou	CC-BY-4.0 e Apache-2.0; degeneram em fragmentos repetidos com e sem token de idioma
OPUS-MT bilíngues `opus-mt-pt-en` e `opus-mt-en-pt`	Inacessíveis	O repositório devolveu 401 na data da medição
M2M100 418M	Candidato por avaliar	Código MIT; licença dos pesos por confirmar no cartão do checkpoint
NLLB-200	Excluído	Pesos CC-BY-NC-4.0
SeamlessM4T v2	Excluído do catálogo normal	Pesos CC-BY-NC-4.0; 29,9 GB

17.2. Decisão

- O caminho principal é NMT por par, com checkpoint aprovado individualmente e executado por CTranslate2.
- Três amostras corretas não validam um par. PT→EN só sobe a candidato prioritário com um conjunto representativo, avaliação por falante nativo e estabilidade em sessão longa.
- EN→PT continua por resolver. O critério de saída é objetivo: um checkpoint redistribuível, com licença confirmada, que produza traduções corretas num conjunto de pelo menos 100 frases com números, negações e nomes próprios, acima do limiar de fidelidade definido na secção 32.
- O Argos sai do núcleo enquanto a cadeia AGPL não tiver conclusão técnica e de licenciamento. Se voltar, volta como integração externa opcional, com a sua licença visível.
- Um modelo de linguagem grande pode existir para polimento de tom, nunca como tradutor por defeito.

18. Clonagem e síntese de voz

A matriz anterior confundia quatro coisas: clonagem a partir de amostra, vozes predefinidas, desenho de voz e síntese neutra. A tabela seguinte separa-as, com a licença e o estado que a auditoria confirmou.

Checkpoint	Tamanho	Licença dos pesos	Clona voz	PT-PT	Papel
Qwen3-TTS 12Hz 0.6B Base	2,52 GB	Apache-2.0	Sim, a partir de áudio de referência	Cobertura PT na família; PT-PT por medir	Candidato de clonagem em CPU
Qwen3-TTS 12Hz 1.7B Base	4,54 GB	Apache-2.0	Sim, a partir de áudio de referência	Idem	Candidato de clonagem em GPU
Qwen3-TTS 1.7B CustomVoice	4,52 GB	Apache-2.0	Não: oferece vozes predefinidas	Idem	Voz neutra de qualidade, não clonagem

Checkpoint	Tamanho	Licença dos pesos	Clona voz	PT-PT	Papel
Qwen3-TTS 1.7B VoiceDesign	4,52 GB	Apache-2.0	Não: desenha voz por descrição	Idem	Desenho de voz, experimental
Chatterbox Multilingual pt-PT	4,26 GB	MIT	Sim	Sim, checkpoint dedicado a português europeu	Candidato prioritário para clonagem PT-PT
Chatterbox Multilingual pt-BR	4,26 GB	MIT	Sim	Não: variante brasileira	Catálogo separado, nunca substituto de PT-PT
VoxCPM2	4,96 GB	Apache-2.0	Sim, zero-shot	Por medir	Experimental
VoxCPM 0.5B	1,61 GB	Apache-2.0	Sim	Por medir	Experimental
Kokoro 82M	0,36 GB	Apache-2.0	Não	Não: apenas pt-BR entre as vozes publicadas	Voz neutra de baixo custo, não fallback PT-PT
Piper, vozes `rhasspy/piper-voices`	12 GB no conjunto	MIT no repositório de vozes; runtime piper1-gpl GPL-3.0-or-later	Não	Sim, voz `pt_PT-tugão-medium`	Voz neutra leve, integração externa opcional
F5-TTS	1,35 GB	Código MIT, pesos CC-BY-NC	Sim	Por medir	Excluído
XTTS-v2	1,86 GB	Coqui Public Model License, não comercial	Sim	Sim	Excluído

18.1. Regras derivadas

- Qwen3-TTS Base 0.6B é o candidato de clonagem para máquinas sem GPU; 1.7B Base é o candidato de qualidade em GPU. Nenhum dos dois é default antes de medir identidade vocal em português europeu.
- CustomVoice e VoiceDesign não preenchem o lugar de um clonador na cadeia da secção 4.1. Apresentá-los como clonagem era o erro corrigido nesta versão.
- Chatterbox Multilingual PT-PT é o único checkpoint com português europeu dedicado entre os candidatos verificados, e por isso recebe prioridade na avaliação, não um estatuto de vencedor.
- Kokoro continua no catálogo como voz neutra barata, para inglês e para brasileiro, e deixa de ser citado como fallback de português europeu sem prova.
- Piper permanece opcional e externo enquanto o runtime for GPL. As vozes são artefactos separados, com a licença do repositório de vozes.
- A clonagem exige consentimento da secção 5, em qualquer motor.

19. Diarização, VAD e alinhamento

Componente	Licença	Estado	Papel
Silero VAD	MIT	Verificado	Deteção de atividade de voz no núcleo
sherpa-onnx	Apache-2.0	Em uso	Runtime de reconhecimento e utilitários de áudio
Diarização sherpa-onnx	Apache-2.0 no runtime; modelos por verificar	Candidato	Diarização offline para Meeting Lite
pyannote	Código MIT; pesos com condições de acesso	Candidato condicionado	Diarização de referência, sujeita a confirmação de redistribuição
Alinhamento forçado	Depende do motor	Candidato	Timestamps por palavra para legendas e dobragem

Regras: nenhuma diarização atribui nomes de pessoas; os falantes são identificados por número e a associação a uma pessoa é um ato manual e local do utilizador. Pesos com condições de acesso não entram em arquivos de release; são descarregados pelo utilizador com a licença à vista.

20. Matriz de modelos por função

Síntese de tudo o que as secções 16 a 19 verificaram. Os estados são operacionais: recomendado entra no modo automático quando os gates fecharem; compatível funciona e não é escolha automática; experimental exige opt-in; bloqueado não é distribuído; externo corre fora do núcleo.

Função	Candidato	Estado	Motivo
Reconhecimento PT-PT por blocos	Parakeet TDT 0.6B v3 int8	Recomendado	Medido em CPU, WER 0,231 no corpus atual
Reconhecimento universal	Whisper large-v3-turbo e variantes	Compatível	Robusto, MIT, cobertura ampla, mais lento
Reconhecimento avançado	Qwen3-ASR 0.6B	Experimental	Licença Apache-2.0 verificada; integração e recursos por medir
Reconhecimento em GPU NVIDIA	Nemotron 3.5 ASR	Experimental	Runtime e licença por confirmar por versão
Tradução PT→EN	OPUS-MT ROMANCE-en por CTranslate2	Candidato	Medido, ainda sem corpus representativo
Tradução EN→PT	Nenhum aprovado	Por resolver	Todos os checkpoints testados falharam
Tradução por par, arquitetura	CTranslate2 com checkpoint aprovado	Recomendado	MIT, rápido, sem dependências copyleft
Tradução contextual	M2M100 418M	Candidato por avaliar	Licença dos pesos por confirmar
Clonagem em CPU	Qwen3-TTS 0.6B Base	Candidato prioritário	Apache-2.0, 2,5 GB, clonagem por referência
Clonagem em GPU	Qwen3-TTS 1.7B Base	Candidato	Apache-2.0, mais qualidade, mais memória
Clonagem PT-PT	Chatterbox Multilingual pt-PT	Candidato prioritário	MIT e checkpoint dedicado a português europeu
Voz neutra barata	Kokoro 82M	Compatível	Não cobre PT-PT; útil para inglês e pt-BR
Voz neutra externa	Piper com vozes MIT	Externo	Runtime GPL fora do núcleo
Desenho de voz	Qwen3-TTS VoiceDesign	Experimental	Não é clonagem; requer rotulagem
Diarização	sherpa-onnx ou pyannote	Candidato	Licenças e pesos por fechar
Deteção de atividade	Silero VAD	Recomendado	MIT, leve, em uso
Modelos de voz não comercial	F5-TTS, XTTS-v2, NLLB, SeamlessM4T	Bloqueado	Licenças não compatíveis com distribuição livre

PARTE V · LICENÇAS E DIREITOS

21. Licenciamento por artefacto

O Parlo distribui tipos de artefacto diferentes, e cada tipo tem a sua licença. A regra que organiza todo o resto: **nada herda a licença de outra coisa**. O código Apache-2.0 do motor não licencia um checkpoint, uma voz, um dataset ou um pacote de terceiros.

Artefacto	Licença no projeto	Obrigações	Onde aparece
Código original (motor, CLI, app, ferramentas, SDK)	Apache-2.0	`LICENSE`, `NOTICE`, aviso de alterações	Repositório e arquivos de release
Releases até v0.1.7	MIT, preservada	Texto original intacto	`licenses/MIT-Parlo-0.1.x.txt`
Adaptadores de modelos	Licença própria conforme o código e as dependências	Documentada por adaptador	Repositório e `LICENSES.md`
Adaptador Piper	GPL-3.0-or-later, porque usa runtime GPL	Texto e código correspondente disponíveis	`engines/tts-piper`, fora dos arquivos de release
Dependências Rust e Python	As dos respetivos autores	Avisos agregados, SBOM	`THIRD_PARTY_NOTICES.md` e SBOM CycloneDX
Pesos de modelos	Por artefacto, registada no catálogo	Atribuição e condições por checkpoint	`catalog/models.json` e `docs/MODEL_LICENSES.md`
Vozes	Por voz, registada individualmente	Nome do autor, origem, condições	Catálogo e área de licenças na aplicação
Datasets de avaliação	Por dataset	Uso interno, sem redistribuição por omissão	Documentação de benchmarks

Consequências práticas: o instalador não transporta pesos; o README declara a licença do código e remete para `LICENSES.md` para tudo o resto; e nenhuma página do projeto descreve uma licença de módulo como se cobrisse os seus componentes.

22. Dependências e risco copyleft

Separar processos é uma decisão de engenharia; a qualificação de obra combinada é uma questão jurídica que este documento não decide. O que o projeto faz é reduzir a exposição e documentar a fronteira com precisão.

Componente	Licença	Risco	Decisão
piper1-gpl	GPL-3.0-or-later	Alto se ligado ao núcleo	Fora do programa do motor; adaptador externo opcional
espeak-ng	GPL-3.0	Alto: é a razão da licença do Piper	Não é dependência do núcleo
argostranslate 1.11.0	MIT declarado	Médio	Em revisão
MiniSBD	AGPLv3	Alto: obrigações de rede	Presente por dependência transitiva do Argos; motivo da saída do Argos do núcleo
CTranslate2	MIT	Baixo	Aceite
sherpa-onnx	Apache-2.0	Baixo	Aceite
faster-whisper	MIT	Baixo	Aceite
numpy, psutil, truststore	BSD, BSD, MIT	Baixo	Aceite
pyannote (pesos)	Condições de acesso	Médio	Não redistribuir pesos; download pelo utilizador

Regras de fronteira: o núcleo não importa código GPL nem AGPL; os adaptadores copyleft vivem em processos separados, com a sua licença, e são instalados por ação explícita do utilizador; o produto funciona sem eles; o protocolo entre núcleo e adaptador é público e documentado; e nenhuma release agrega um binário copyleft ao pacote principal. A documentação diz que esta fronteira é técnica e que a qualificação jurídica de distribuição conjunta fica para parecer, quando existir.

Decisão fechada: o Argos deixa de ser dependência obrigatória do núcleo. A integração pode permanecer como adaptador externo opcional, documentado, mas nenhuma cadeia que inclua MiniSBD volta ao caminho principal sem análise específica e decisão registada.

23. Pesos, vozes e datasets

Cada artefacto descarregável tem um registo com: identificador e versão, origem oficial, URL, hash, licença, atribuição obrigatória, condições conhecidas e estado de verificação. O procedimento é o mesmo para todos:

- Abrir a fonte oficial e ler a licença declarada para aquele checkpoint, não para a família.
- Registar o commit ou a revisão exata descarregada.
- Calcular o hash do ficheiro distribuído e guardá-lo no catálogo.
- Registar a licença das vozes ou dos dados em campo próprio, separado do código.
- Marcar como não verificado tudo o que não foi confirmado, e impedir a admissão pelo orquestrador enquanto assim estiver.

Estado atual: as três vozes Piper incluídas estão verificadas como MIT no repositório de vozes, o checkpoint Qwen3-ASR 0.6B está verificado como Apache-2.0, e o pacote Argos é o único artefacto ainda marcado como não verificado — precisamente o que está a sair. Nenhum peso de modelo é distribuído dentro de um arquivo de release.

24. Modelos bloqueados e catálogo experimental

Categoria	Comportamento
Aprovado	Download em um clique, hash verificado, licença visível
Experimental	Área separada, aviso com fonte, licença, desconhecidos e consequência, opt-in explícito
Bloqueado	Não aparece para download; aparece a razão na documentação
Externo	Instalado fora do Parlo, com contrato de processo e licença própria

Ficam bloqueados: F5-TTS (pesos CC-BY-NC), XTTS-v2 (licença não comercial), NLLB-200 e SeamlessM4T v2 (CC-BY-NC), e qualquer checkpoint cuja licença não tenha sido confirmada. Ficam experimentais: Qwen3-ASR, VoxCPM, VoiceDesign e diarização com pesos condicionados. Ficam externos: Piper e Argos, se o Argos voltar.

Um modelo bloqueado pode ser usado por quem o instalar por sua conta, mas o Parlo não o descarrega, o PIMO não o admite na seleção automática e o produto não o apresenta como capacidade.

Estado do Argos: sai do núcleo e das dependências obrigatórias. Fica documentado como possibilidade experimental futura, sujeita à resolução da cadeia AGPL, e não aparece na distribuição normal.

25. Direitos de voz e uso aceitável

O Parlo exige o mínimo necessário para ser um projeto responsável, sem transformar a utilização normal num formulário.

Situação	Exigência
A própria voz	Declaração de que a voz é do utilizador
Voz de outra pessoa	Declaração de autorização, com finalidade e âmbito, registada localmente
Voz de ator, dataset ou voz comercial	Proibida como exemplo ou demonstração no repositório
Vozes de exemplo na documentação	Só sintéticas neutras ou do próprio autor do exemplo
Vozes pré-instaladas	Não existem
Cópia do repositório	Não contém amostras de voz privadas, nem perfis, nem caches

O registo é uma declaração local, não uma certificação de identidade. O projeto não promete verificar quem é quem; promete não clonar sem declaração, permitir revogar e apagar, e recusar conteúdo que se apresente como outra pessoa para enganar. O âmbito completo está em `ACCEPTABLE_USE.md` e na política de voz publicada no repositório.

26. Conformidade automática em cada release

A conformidade deixa de depender de memória. O que existe hoje: um gate que lê a cadeia Rust por `cargo metadata`, a cadeia Python pelas dependências fixadas e o catálogo de modelos, e falha quando uma licença falta, está negada, sai da allowlist do âmbito ou aparece numa dependência sem versão fixa; avisos de terceiros e SBOM CycloneDX gerados do mesmo inventário; índice de licenças regenerado e comparado com o commit; e recusa de build enquanto o gate tiver problemas abertos.

Controle	Efeito	Estado
Allowlist por âmbito	GPL só em adaptadores opcionais, nunca no núcleo	Implementado
Dependências fixadas	Nenhuma versão flutuante em Rust ou Python	Implementado
SBOM CycloneDX por release	Inventário com versões e hashes	Implementado
`THIRD_PARTY_NOTICES.md`	Avisos agregados	Implementado
`LICENSES.md` validado no CI	Índice coerente com o catálogo	Implementado
Verificação de artefactos de modelo	Falha quando falta licença, hash ou estado	Implementado no catálogo; falta bloquear a admissão
Hashes de binários de release	Registo por artefacto	Implementado
Builds reprodutíveis	Sem dependência do ambiente de quem compila	Parcial: falta fixar toolchain e imagem

O gate prova coerência de metadados, não conformidade jurídica. Uma dependência nova com licença aprovada na allowlist pode ainda criar obrigações que exigem leitura humana; por isso a allowlist é revista por componente e as exceções ficam registadas na secção 80, não escondidas num ficheiro de configuração.

PARTE VI · ORQUESTRAÇÃO INTELIGENTE, MODEL HUB E AUTO SELECT

27. Arquitetura de orquestração: PIMO e fronteiras

O **Parlo Intelligent Model Orchestrator** é o componente que decide, em cada momento, qual modelo serve a tarefa pedida naquele dispositivo. Não é um modelo de machine learning que aprende a escolher; é um motor de decisão determinístico sobre manifestos, perfil de hardware, licenças e resultados de benchmark guardados localmente. Essa escolha é deliberada: um seletor com regras auditáveis explica-se, testa-se e não surpreende o utilizador.

Componente	Responsabilidade	Não faz
PIMO	Filtrar, avaliar, selecionar, compor pipeline, monitorizar e trocar	Não descarrega ficheiros, não guarda perfis de voz
Model Hub	Ciclo de vida dos artefactos: download, hash, instalação, atualização, remoção	Não escolhe modelos
Auto Select	Regra de produto que expõe o PIMO ao utilizador	Não tem lógica própria de avaliação
Hardware Profiler	Mede o dispositivo e o que está livre naquele momento	Não testa modelos
Runtime Manager	Arranca, vigia e termina processos de motor	Não decide qual motor
Voice Profile Manager	Guarda perfis, representações por motor e consentimento	Não escolhe motor de clonagem
Benchmark Store	Guarda resultados com chave de validade	Não interpreta resultados

27.1. Interfaces

Interface	Entrada	Saída
`plan(task, locale, mode)`	Tarefa, idioma e variante, modo de utilização, perfil de voz	Plano de execução com candidatos ordenados e razão
`admit(model)`	Manifesto e hardware atual	Elegível, eliminado com motivo, ou pendente de teste
`probe(model)`	Candidato elegível	Resultado técnico do nível B
`observe(metrics)`	Latência, memória, erros da sessão	Evento de degradação ou de estabilidade confirmada
`recover(failure)`	Falha tipificada	Próximo candidato ou degradação declarada
`explain(plan)`	Plano	Frase legível para a interface e registo técnico

27.2. Regras de fronteira

- O PIMO não escreve no catálogo nem instala nada; pede ao Model Hub e espera confirmação de hash.
- O Model Hub não conhece preferências de qualidade; só estados de artefacto.
- O Voice Profile Manager é a única peça que lê amostras de voz, e o PIMO só recebe metadados de compatibilidade, nunca o áudio.
- Toda a decisão é registada com os sinais que a produziram, para que uma troca de comportamento seja diagnosticável meses depois.

28. Manifesto por modelo e níveis de evidência

Cada entrada do catálogo declara, no mínimo: identificador e versão; tarefa; projeto de origem; URL oficial; hash SHA-256; licença do código, dos pesos e de dados ou vozes; idiomas e variantes efetivamente validadas; funcionalidades; arquitetura; runtime; sistemas operativos; CPU, GPU e aceleradores; RAM e VRAM mínimas e recomendadas; armazenamento; formatos e quantizações; compatibilidade com outros componentes; resultados de benchmark; limitações conhecidas; estado de manutenção; proveniência e versão do manifesto.

28.1. Níveis de evidência

Nível	Significado	Pode ser default?
Declarado	O fabricante afirma; o Parlo não confirmou nada	Não
Documentado	Confirmado em documentação oficial consultada	Não
Validado	Passou os testes do Parlo naquele runtime e configuração	Sim
Experimental	Funciona, com limitações conhecidas e opt-in	Não
Não confirmado	Proveniência, licença ou integridade insuficientes	Não

Uma capacidade anunciada nunca é apresentada como validada pelo Parlo. O manifesto guarda os dois campos em separado — o que a origem declara e o que o projeto mediu — e a interface mostra sempre o segundo.

28.2. Manifesto incompleto

Campo obrigatório em falta impede a entrada no modo automático, mas não esconde o modelo: a entrada aparece como não confirmada, com o campo em falta nomeado. O catálogo atual cobre licença, origem, hash e estado de verificação; faltam cobertura de hardware, latência medida, regra de recomendação e versão de manifesto.

29. Descoberta e filtragem eliminatória

Antes de qualquer teste, o PIMO reduz o universo por metadados. Um candidato eliminado nunca é executado.

Filtro	Critério
Tarefa	O manifesto declara a tarefa pedida
Idioma e variante	Cobertura declarada e, quando existir, validada para a variante
Licença	Compatível com a política do projeto para o âmbito de distribuição
Sistema operativo	Suporte confirmado no sistema atual
Recursos	RAM, VRAM e disco compatíveis com o que está realmente livre
Voz	Capacidade de preservar os requisitos do Voice Profile, quando a clonagem é exigida
Integridade	Hash disponível e proveniência verificável
Segurança	Sem problemas conhecidos de integridade, execução arbitrária ou vulnerabilidade aberta

Ordem e custo: filtros de metadados primeiro, hardware depois, licença antes de qualquer download. Um candidato sem licença confirmada para o âmbito ativo é eliminado sem gastar rede nem CPU — uma inversão que poupa tempo e evita distribuir o que não pode ser distribuído.

30. Perfil automático do dispositivo

O Hardware Profiler mede o dispositivo localmente e distingue capacidade instalada de recursos realmente disponíveis.

Medição	Uso
Sistema operativo e versão	Compatibilidade de runtime
Arquitetura e instruções	Escolha de build e de quantização
Núcleos físicos e lógicos	Paralelismo real, não threads teóricas
RAM total e livre	Admissão de modelos e margem de segurança
GPU e aceleradores	Backend disponível e VRAM livre
Backends possíveis	CUDA, ROCm, Metal, DirectML, CPU
Disco livre	Download e instalação
Velocidade de armazenamento	Tempo de carregamento em modelos grandes
Carga atual	Decisão de arranque sem competir com o sistema

30.1. O que nunca é assumido

- Que duas máquinas com a mesma RAM têm o mesmo desempenho.
- Que uma GPU instalada está utilizável pelo backend disponível.
- Que a memória livre no arranque se mantém durante uma sessão.
- Que as especificações teóricas substituem uma medição de latência.

O perfil é obtido sem enviar informação do dispositivo para fora e sem testes agressivos. Nenhuma sonda de stress entra no arranque normal; a validação pesada ocorre em desenvolvimento e em integração contínua.

31. Avaliação em três níveis

Nível	Onde corre	O que produz	Custo
A · estática	Sempre, no arranque	Lista de elegíveis e motivos de eliminação	Desprezável
B · validação técnica	Primeira utilização de um candidato naquele dispositivo	Integridade, carregamento, memória, latência, validade	Segundos
C · qualidade aprofundada	Desenvolvimento, CI e atualização de modelo	Qualidade, estabilidade, robustez, reprodutibilidade	Minutos a horas

31.1. Nível B

Verifica hash e carregamento, compatibilidade de runtime, memória consumida, tempo de inicialização, latência da primeira e das inferências seguintes, validade do resultado e libertação de recursos no descarregamento. Usa amostras pequenas e representativas. Interrompe quando houver risco de esgotamento de memória, instabilidade ou consumo anómalo. Um teste técnico bem-sucedido não é uma validação de qualidade, e o resultado guarda essa distinção.

31.2. Nível C

Avalia qualidade, precisão, naturalidade, inteligibilidade, latência, estabilidade, consumo e reprodutibilidade, com o corpus e as condições registados. Corre no repositório, com os scripts de avaliação existentes — `battery.py`, `stt_bench.py`, `compare.py`, `soak.py` e `stream_bench.py` —, e não na máquina do utilizador. Resultados aprofundados são reutilizados quando modelo, runtime, configuração, ambiente e versão do benchmark coincidem.

32. Benchmarks com evidência por tarefa

Uma pontuação única não compara modelos de tarefas diferentes. Cada categoria tem as suas métricas e o seu conjunto de testes.

Tarefa	Métricas	Cuidados
Reconhecimento	WER, CER, pontuação e segmentação, timestamps, robustez a ruído, vocabulário	PT-PT e PT-BR em separado; sotaques declarados
Tradução	BLEU, chrF, COMET quando disponível, preservação de números e negações, terminologia, fluidez	Ambas as direções; conjunto representativo; validação humana no desenvolvimento
Clonagem e síntese	Semelhança de locutor, naturalidade, inteligibilidade, pronúncia, prosódia, consistência entre frases, estabilidade em sessão, latência, memória	Semelhança é indicador, não prova de identidade preservada
Tempo real	P50 e P95 do primeiro resultado, do primeiro áudio e do total, atraso acumulado, jitter, perdas	Distinguir latência de componente de latência de experiência

O corpus de avaliação é escrito para o projeto e versionado com o código: frases curtas e longas, conversa formal e informal, vocabulário técnico, números, datas, nomes próprios e expressões idiomáticas, em português europeu, português brasileiro e inglês, nos dois sentidos de tradução. Os textos originais ficam sob CC0-1.0 e a origem é registada. Não se usam mensagens privadas nem texto de terceiros sem autorização.

Um corpus escrito mede tradução, não reconhecimento. Para reconhecimento são necessárias gravações autorizadas, e a diferença é declarada em cada resultado.

Regra de publicação: um número aparece com modelo, versão, quantização, runtime, threads, hardware, corpus e data. Média sem condições não entra em notas de release. Métricas automáticas não substituem avaliação humana nos pares de línguas e nas vozes que o produto declara suportar.

33. Seleção multicritério

O PIMO ordena os candidatos aptos com prioridades fixas e pesos por tarefa, definidos a partir de medições. Nunca inventa pontuações.

Ordem	Critério	Efeito
1	Requisitos funcionais e legais	Elimina, não pontua
2	Preservação da identidade vocal, quando pedida	Elimina se não houver suporte técnico
3	Qualidade mínima validada	Elimina abaixo do limiar da tarefa
4	Compatibilidade técnica	Elimina se o dispositivo não serve
5	Estabilidade	Desempata com peso alto
6	Latência adequada ao modo	Desempata; nunca compensa qualidade em falta
7	Eficiência de recursos e energia	Desempata no fim

Incerteza: quando não há dados suficientes para comparar dois candidatos, o PIMO prefere o que já está validado para aquele contexto e regista a decisão como conservadora. Se nenhum candidato cumprir a qualidade mínima, o resultado correto não é escolher o menos mau em silêncio: é declarar que a tarefa não tem motor adequado e degradar segundo a secção 36.

A explicação tem duas camadas: uma frase na interface — «Escolhi este modelo porque cobre PT-PT, cabe em 3,1 GB livres e tem a menor latência medida nesta máquina» — e um registo técnico com os sinais, os pesos e os candidatos eliminados.

34. Composição de pipeline

O melhor sistema raramente é um só fornecedor. O PIMO escolhe por etapa — reconhecimento, tradução, clonagem, processamento auxiliar — e avalia o conjunto.

Risco de combinação	Como é tratado
Latência acumulada	Orçamento por etapa; soma medida, não estimada
Incompatibilidade de formatos	Contrato de amostras, taxas e canais no adaptador
Perda de contexto na tradução	Unidades semânticas e contexto de sessão definidos fora dos motores
Conflito de memória	Soma de RSS e VRAM dos motores ativos verificada antes de compor
Dessincronização de áudio	Timestamps monotónicos no núcleo, não no motor
Dependências adicionais	Cada motor extra tem de justificar o seu custo em qualidade medida

Regra: três modelos individualmente excelentes que produzem pior experiência composta não são escolhidos. A unidade de decisão é o pipeline, não o componente.

35. Monitorização de runtime e adaptação

Durante a utilização, o PIMO observa latência real, erros, RAM e VRAM, falhas de inferência, saturação, tempo de resposta e estabilidade. Reage quando as condições mudam, com mecanismos que evitam oscilação.

Mecanismo	Regra
Período mínimo de permanência	Uma configuração fica ativa durante um mínimo antes de poder ser trocada
Histerese	A alternativa tem de ser claramente melhor, não marginalmente melhor, para justificar troca
Circuit breaker	Falhas repetidas do mesmo motor retiram-no da seleção durante um período definido
Limite de tentativas	Número finito de recuperações por sessão, com degradação declarada quando se esgota
Limite de recursos	Interrupção segura antes de esgotar memória, com o texto já reconhecido preservado
Fronteira segura	A troca acontece entre segmentos e nunca a meio de uma frase ou de uma emissão de voz

Se a latência subir de forma persistente, o PIMO investiga a causa antes de trocar: pode ser fila acumulada, thermal throttling, contenção de memória ou um modelo inadequado. Trocar de modelo para resolver um problema de fila só piora o diagnóstico.

36. Fallback e proteção da identidade vocal

Antes de mudar de motor, o PIMO confirma compatibilidade funcional, linguística, de qualidade mínima, de dados existentes, de perfil de voz e de recursos. Um fallback que perde o requisito essencial da tarefa não é um fallback: é uma degradação, e tem de ser declarada.

Situação	Comportamento
Motor falha, alternativa compatível existe	Troca, sem interromper, com aviso depois do segmento
Clonador falha, outro clonador serve o mesmo perfil	Troca apenas se a representação para esse motor existir ou puder ser derivada
Clonador falha, nenhum outro serve	Declara que a identidade vocal não pode ser garantida e oferece voz neutra identificada ou só texto
Perfil não tem representação para o motor de destino e a amostra foi apagada	Não troca; explica que é necessário gravar de novo
Nenhum motor com qualidade mínima	Declara a limitação e mantém o texto

Regras de voz que o PIMO nunca viola: não assume embeddings compatíveis entre motores; não usa voz genérica como substituição silenciosa; não promete preservação de identidade sem medição naquele motor; e não decide sozinho apagar ou substituir um perfil.

37. Model Hub e ciclo de vida

Estado	Entrada	Saída
Descoberto	Entra no catálogo	Verificação de proveniência e licença
Verificado	Licença, hash e proveniência confirmados	Download disponível
Instalado	Ficheiros presentes e hash validado	Validação técnica
Validado	Passou o nível B naquele dispositivo	Elegível para seleção automática
Ativo	Em uso numa sessão	Desativação ou remoção
Desativado	Fora de uso, ficheiros mantidos	Remoção ou reativação
Removido	Ficheiros e caches eliminados	Nova instalação exige download

Regras: nada executa sem hash validado; nenhum download silencioso; espaço verificado antes de descarregar; nenhuma atualização de modelo durante sessão ativa; rollback para a última versão validada sempre disponível; e uma atualização nunca substitui uma versão estável sem validação prévia. Pesos de terceiros nunca entram nos arquivos de release.

38. Cache de resultados e reutilização

Cada resultado de validação fica associado a modelo e versão, hash dos ficheiros, runtime e versão, configuração e quantização, hardware relevante, sistema operativo, versão do benchmark, dataset, data e estado de validade.

Mudança	Efeito na cache
Mesma máquina, mesmo tudo	Resultado reutilizado
Atualização do modelo ou do runtime	Invalida o resultado do nível B e do nível C
Alteração de quantização ou configuração	Invalida
Hardware muito diferente	Não reutiliza; repete o nível B
Nova versão do benchmark	Invalida o nível C, mantém o histórico para comparação

O PIMO não repete testes sem razão concreta e não reutiliza resultados de ambientes que não sejam equivalentes. A cache é local, apagável e nunca sai do dispositivo.

39. Privacidade e segurança da orquestração

- Nenhum benchmark envia áudio, amostras vocais, embeddings, transcrições ou métricas para terceiros.
- Datasets de avaliação são autorizados e controlados; os de desenvolvimento não são distribuídos com o produto.
- Manifestos, downloads e caches têm verificação de integridade; um manifesto adulterado é rejeitado.
- Nenhum código de modelo corre sem proveniência verificável e hash confirmado.
- Limites de recursos e interrupção segura fazem parte da orquestração, não são opcionais.
- O registo técnico de decisões não inclui conteúdo do utilizador, apenas identificadores de modelo, métricas e motivos.

40. Experiência do utilizador e transparência

O utilizador não escolhe motores, não compara modelos, não conhece RAM nem VRAM, não instala dependências e não resolve conflitos. Vê apenas o que lhe é útil: o estado da operação, o modelo em uso quando isso explica alguma coisa, limitações, necessidade de espaço ou de download, e avisos de qualidade ou de preservação de voz.

Situação	O que aparece
Tudo normal	Estado e resultado, sem jargão
Escolha relevante	Uma frase com o motivo
Troca de motor	Aviso curto, com o que mudou
Degradação de voz	Aviso explícito de que já não é a voz da pessoa
Falta de espaço ou download	Tamanho, destino e uma ação
Nenhum motor adequado	Explicação e a alternativa segura que resta

O modo automático é a experiência completa, não uma versão reduzida. As definições avançadas existem para quem quer fixar um motor, e nesse caso o produto diz que a escolha deixa de ser automática e passa a ser verificada de outra forma.

41. Testes automáticos da orquestração

Testes sem modelos reais, com manifestos e métricas simulados, cobrem o que é lógica pura: filtragem, ordenação, empates, incerteza, histerese, limites de tentativas, circuit breaker, invalidação de cache e composição de pipeline. Testes com modelos reais ficam reservados ao nível B num único modelo pequeno e ao nível C em CI.

Teste	O que garante
Eliminação por licença	Nenhum candidato sem licença sobrevive ao nível A
Eliminação por recursos	Um modelo que não cabe nunca é admitido
Histerese	Uma variação pequena de latência não muda de motor
Circuit breaker	Falhas repetidas retiram o motor e o produto continua
Falha de GPU	Cai para CPU com aviso e sem perder texto
Perfil sem representação	Não troca de motor e explica porquê
Cache inválida	Resultado antigo não é usado depois de mudar a configuração
Regressão de qualidade	Uma versão nova com pior qualidade medida não substitui a anterior

42. Critérios de aceitação do PIMO

1. Filtra automaticamente modelos incompatíveis, com motivo registado.
2. Identifica elegíveis sem executar benchmarks extensivos.
3. Valida tecnicamente os candidatos que escolhe, num tempo aceitável.
4. Reutiliza resultados ainda válidos e repete só quando algo mudou.
5. Seleciona modelos diferentes para tarefas diferentes, com justificação.
6. Compõe motores sem degradar o pipeline face a um só motor.
7. Monitoriza desempenho durante a utilização.
8. Deteta e recupera de falhas sem intervenção técnica.
9. Faz fallback respeitando ou declarando a identidade vocal.
10. Evita mudanças constantes e desnecessárias.
11. Gere versões com rollback e sem substituições não validadas.
12. Opera localmente sem transmitir dados pessoais.

13. Explica decisões e limitações de forma compreensível.

14. Não exige escolha técnica do utilizador para funcionar normalmente.

43. Fases de implementação do PIMO

Fase	Trabalho	Conclusão
P1	Manifesto completo e níveis de evidência no catálogo	Todos os candidatos com campos obrigatórios e evidência declarada
P2	Filtro do nível A e Hardware Profiler	Elegíveis e motivos de eliminação visíveis e testados
P3	Validação do nível B com cache	Um modelo real validado, cache invalidada nas mudanças certas
P4	Seleção multicritério e explicação	Escolha estável, explicada e coberta por testes
P5	Monitorização, histerese e recuperação	Sessão de 30 minutos sem oscilação nem perda de texto
P6	Composição de pipeline e fallback de voz	Cadeia completa com degradação declarada

A ordem é uma dependência, não um calendário. P1 e P2 não precisam de nenhum motor novo; P3 exige o par de tradução resolvido e um clonador medido. A implementação reutiliza o que existe — catálogo, gate de licenças, adaptadores por processo e scripts de avaliação — e não cria um sistema de aprendizado para escolher modelos, porque regras determinísticas sobre manifestos e resultados bastam.

PARTE VII · BIBLIOTECA MODULAR DE MODELOS

44. Duas camadas: aplicação e biblioteca

O Parlo separa o que é plataforma do que é conteúdo. A aplicação contém a experiência, a inteligência de decisão e a infraestrutura de execução; a biblioteca contém os modelos que cada utilizador escolhe instalar.

Camada	Contém	Não contém	Cresce com o catálogo?
Aplicação	Interface, PIMO, Model Hub, Auto Select, Runtime Manager, gestor de perfis de voz, componentes essenciais de processamento, cliente de catálogo	Pesos, checkpoints, coleções de vozes, datasets	Não
Biblioteca	Artefactos de reconhecimento, tradução, clonagem, síntese, VAD, diarização, processamento auxiliar, idiomas e variantes	Código da aplicação	Sim, indefinidamente
Dados do utilizador	Perfis de voz, transcrições, traduções, histórico, preferências	Modelos	Não

Regra de dimensionamento: o instalador não incorpora pesos e não pode crescer porque a biblioteca ganhou modelos. Uma versão nova da aplicação pode ser maior por código novo, nunca por catálogo novo.

Orçamento de tamanho: 100 MB é o objetivo do instalador sem modelos, e 150 MB o limite de referência da primeira versão. Se o objetivo for excedido, a release nomeia os componentes responsáveis pelo excesso e documenta o desvio. Segurança, estabilidade e funcionalidades essenciais não se cortam para cumprir um número.

Os dados do utilizador vivem numa terceira área, separada das duas anteriores, e sobrevivem a qualquer atualização ou remoção de modelo.

45. Contratos entre aplicação, biblioteca e runtimes

Os gestores nomeados na arquitetura não são processos separados nem serviços concorrentes: são módulos com fronteiras testáveis, dentro de duas peças que já existem no plano — o PIMO e o Model Hub. Criar processos autónomos para cada um duplicaria estado e criaria corridas de decisão.

Módulo	Onde vive	Responsabilidade	Não faz
Model Manifest Manager	Model Hub	Lê, valida e versiona manifestos	Não decide seleção
Model Compatibility Manager	Model Hub, consultando o PIMO	Calcula compatibilidade com aplicação, runtime, SO e hardware	Não descarrega
Model Download Manager	Model Hub	Descarrega, retoma, verifica hash, instala atomicamente	Não avalia qualidade
Model Security and Integrity Manager	Model Hub	Proveniência, assinatura, hashes, proteção contra downgrade	Não escolhe modelos
Model Studio	Model Hub (superfície avançada)	Importa artefactos externos com verificação	Não promove a validado
Runtime Manager	Núcleo	Arranca, vigia e termina processos de motor	Não instala modelos
PIMO	Núcleo	Filtra, avalia, seleciona e monitoriza	Não escreve no catálogo
Auto Select	Interface sobre o PIMO	Regra de produto e explicação ao utilizador	Não tem lógica de avaliação própria

O contrato entre camadas é explícito: a aplicação conhece o catálogo por uma versão de esquema declarada; cada modelo declara a gama de esquemas e runtimes que suporta; o Runtime Manager recusa arrancar um motor cuja versão de protocolo não esteja na gama aceite. Nenhuma camada lê ficheiros de outra por caminhos implícitos.

46. Catálogo evolutivo e descoberta de novidades

O catálogo é metadado, não peso. Atualiza-se de forma independente da aplicação e independente dos downloads.

Elemento	Onde vive	Regra
Catálogo, manifestos e hashes	Repositório público dedicado, `parlo-models`	Versionado, assinado e independente da aplicação
Pesos e vozes	Fontes oficiais e armazenamento próprio de artefactos	Não entram no Git nem no instalador
Cliente de catálogo	Aplicação	Lê um esquema versionado de uma origem fixa
Origem alternativa	Qualquer hospedagem estática ou CDN	Mudar de origem não exige alterar a aplicação

1. É publicada uma versão da aplicação.
2. A biblioteca recebe modelos novos, sem tocar na aplicação.
3. O cliente atualiza o catálogo e descobre as novidades.
4. O PIMO verifica quais são compatíveis com aquele dispositivo.
5. O Model Hub apresenta as novidades relevantes e as recomendações.
6. O utilizador decide o que instalar.
7. Só os modelos escolhidos são descarregados.

Regras: descobrir não descarrega; atualizar o catálogo não substitui modelos instalados nem altera preferências; uma entrada nova entra como não instalada, mesmo que seja claramente melhor para aquele dispositivo. Se o catálogo não puder ser atualizado, a aplicação funciona com a cópia local e diz há quanto tempo não é atualizada. A consulta ao catálogo é a única chamada externa permitida e não transporta áudio, conteúdo, perfis nem identificadores de utilizador: envia a versão da aplicação e do esquema.

47. Compatibilidade entre versões

Cada modelo declara: gama de versões de API do catálogo e do protocolo; versões de runtime compatíveis; dependências; formatos e quantizações; requisitos de hardware; sistemas operativos; funcionalidades disponíveis; limitações conhecidas; e requisitos de migração, quando existirem.

Dimensão	Como é verificada	Consequência de falha
API do catálogo	Gama declarada contra a versão da aplicação	Modelo não aparece como instalável
Protocolo de motor	Versão negociada no arranque	Motor não arranca; erro legível
Runtime e bibliotecas	Presença e versão mínima	Modelo marcado incompatível
Formato e quantização	Assinatura do ficheiro	Não é admitido
Hardware	Perfil medido, não estimado	Aparece como não recomendado, com razão
Migração	Passos declarados	Instalação bloqueada até migrar

A compatibilidade é calculada, não prometida. Um modelo incompatível nunca é apresentado como funcional, e um modelo descontinuado mantém-se visível com a razão e a alternativa. Introduzir modelos novos não pode degradar instalações existentes: um catálogo novo sem modelo compatível deixa a configuração atual intacta.

48. Instalar, remover e substituir

O utilizador pode instalar, desinstalar, substituir, manter várias versões, manter vários modelos para a mesma tarefa, filtrar por idioma, instalar alternativas, restaurar versões anteriores, libertar espaço, ver o espaço ocupado, ver dependências partilhadas e ver que modelos a configuração atual usa.

Operação	Regra
Instalar	Espaço verificado, hash validado, instalação atómica
Substituir	Nova versão instalada ao lado; troca só depois de validação
Manter versões	Permitido, com aviso de espaço e de modelo em uso
Remover	Protege dependências partilhadas de outros modelos
Remover modelo em uso	Exige confirmação, oferece alternativa ou regresso ao automático
Restaurar versão	Volta à última validada, sem descarregar de novo
Desinstalar	Nunca apaga perfis, configurações ou dados pessoais

A remoção de um modelo não toca em dados do utilizador. Apagar dados vocais é uma operação própria, explícita e irreversível apenas quando o utilizador confirma.

49. Otimização de armazenamento e recursos partilhados

Mecanismo	Comportamento
Estimativa antes do download	Tamanho comprimido e expandido, mais margem
Verificação de espaço	Bloqueia antes de começar, não a meio
Recursos partilhados	Um ficheiro comum é guardado uma vez e referenciado por vários modelos, quando a licença o permitir
Deduplicação	Identificação por hash, nunca por nome de ficheiro
Versões antigas	Mantidas por política declarada, nunca infinitamente
Ficheiros temporários	Limpeza automática de downloads incompletos e cache órfã
Modelos sem uso	Identificados e apresentados; remoção só com autorização
Limpeza controlada	Pré-visualização do que sai e quanto espaço liberta

Nunca se elimina automaticamente um modelo ou versão de que o utilizador dependa. A deduplicação só acontece quando a licença de cada artefacto o permite: dois modelos com licenças diferentes não partilham ficheiros só porque o conteúdo é igual.

50. Biblioteca curada e personalizada

A biblioteca não mostra tudo a todos. Organiza por categoria, função, idioma, variante, qualidade validada, hardware, tamanho, latência, compatibilidade, licença e estado de validação.

Estado	Significado	Pode instalar?
Recomendado para este dispositivo	Validado e adequado ao hardware e ao idioma	Sim, com um clique
Validado pelo Parlo	Passou os gates, não é a melhor escolha local	Sim
Compatível, não totalmente validado	Deve funcionar, com margem de dúvida	Sim, com aviso
Experimental	Opt-in explícito, fora do modo automático	Sim, com aviso detalhado
Incompatível	Falta hardware, runtime, versão de API ou licença	Não; mostra o motivo
Descontinuado	Substituído por outro artefacto	Sim, com aviso e alternativa

Modelos avançados continuam visíveis mesmo quando não são recomendados: um utilizador com uma workstation quer saber que existem. O que nunca acontece é apresentá-los sem a limitação ao lado.

51. Avaliação de novidades pelo PIMO

Quando a biblioteca ganha modelos, o PIMO compara-os com a configuração instalada em qualidade, identidade vocal, idiomas, desempenho, memória, latência, compatibilidade, estabilidade e licença.

Situação	Comportamento
Novidade claramente melhor e compatível	Aparece como recomendação com a razão e o ganho medido
Novidade equivalente	Não é sugerida; evita ruído
Novidade melhor mas exige download grande	Recomendação com custo explícito
Novidade sem validação	Experimental, fora do modo automático
Utilizador recusou a novidade	A recusa é registada e a sugestão não volta a aparecer

O Parlo recomenda, nunca instala nem substitui sem autorização. A configuração automática continua funcional com o que está instalado, mesmo que o utilizador ignore todas as novidades durante meses.

52. Importação de modelos externos

O Model Studio aceita artefactos externos quando o formato, o runtime e a arquitetura são suportados. Antes de aceitar, verifica proveniência, integridade, hash quando disponível, licença e termos, formato, dependências, compatibilidade técnica, requisitos de hardware e riscos de segurança.

Verificação	Falha
Proveniência declarada	Importação recusada
Integridade e hash	Importação recusada
Licença identificável	Importação recusada
Formato e runtime suportados	Importação recusada com a lista do que falta
Compatibilidade de hardware	Importado como incompatível, não executável
Código executável dentro do pacote	Recusado por omissão

Três categorias ficam sempre distintas na interface: importado, oficial da biblioteca e validado pelo Parlo. Um modelo importado pode ser usado, mas fica fora da seleção automática de produção até validação; e nenhum pacote corre código arbitrário só porque traz um modelo lá dentro.

53. Distribuição segura e atualizações atómicas

Controle	Efeito
Manifesto assinado com Ed25519	Autenticidade da origem, além da integridade
Chave pública embutida na aplicação	Verificação sem depender da rede nem de uma autoridade externa
Chave privada fora do repositório	Guardada pelo mantenedor, nunca versionada, com procedimento escrito
Rotação de chave	Duas chaves aceites durante a transição, com aviso de validade
Recuperação	Procedimento documentado para substituir uma chave comprometida
Hash SHA-256 por ficheiro	Integridade depois do download
Transporte seguro	Nada por canais não autenticados
Proteção contra downgrade	Versão mais antiga não substitui a atual sem pedido explícito
Retoma de download	Interrupção não obriga a recomeçar

Controle	Efeito
Instalação atómica	Falha deixa o estado anterior funcional
Rollback	Atualização problemática reverte sem reinstalar tudo
Histórico de alterações	Cada versão de catálogo e de modelo tem registo

A assinatura é o que distingue autenticidade de integridade: um hash confirma que o ficheiro não mudou depois de descarregado, mas não prova quem o publicou. Por isso o manifesto é assinado e a chave pública viaja dentro da aplicação.

O instalador Windows não tem assinatura Authenticode nesta fase. Publicam-se hashes SHA-256 e instruções de verificação, com o aviso honesto de que o Windows mostrará alertas de origem desconhecida. Os hashes não são apresentados como substituto da assinatura de código, e o processo de distribuição fica preparado para acrescentar Authenticode sem ser reescrito.

54. Ciclos de atualização independentes

Ação	Efeito
Atualizar a aplicação	Modelos instalados continuam válidos e não são descarregados de novo
Atualizar a biblioteca	Aplicação não é atualizada
Instalar modelo novo	Nada mais muda
Remover modelo	Nada mais muda, exceto o espaço livre

Uma atualização da aplicação só é obrigatória quando muda a API do catálogo, o protocolo de motor ou a interface de um componente essencial. Esses casos são declarados: o catálogo diz qual é a versão mínima da aplicação e a aplicação diz o que ganha ao atualizar. Compatibilidade retroativa é a regra; rotura é a exceção documentada.

55. Dois modos de utilizador

Modo	Experiência	Quem usa
Automático	A aplicação identifica o dispositivo, o PIMO escolhe, o Model Hub instala o necessário, as novidades aparecem quando relevantes	Experiência completa e predefinida
Avançado	Biblioteca completa, instalação individual, importação, versões, preferências por idioma e tarefa, controlo de atualizações e de espaço	Quem quer decidir

No primeiro arranque, o Parlo analisa o dispositivo e apresenta uma configuração recomendada, com o tamanho total, a finalidade de cada modelo, o espaço disponível e uma estimativa de utilidade por ligação. A instalação da configuração recomendada faz-se com uma confirmação; instalar apenas parte dela é igualmente simples. Nada é descarregado sem essa confirmação, e a biblioteca completa nunca é proposta de uma vez.

O modo avançado não é requisito de qualidade: um utilizador que nunca o abra tem a melhor configuração que o dispositivo permite. Existe para quem quer fixar escolhas, importar artefactos ou limitar downloads, e nesse caso o Parlo diz que a escolha deixou de ser automática.

PARTE VIII · ARQUITETURA E PLATAFORMA

56. Camadas, núcleo e isolamento

Camada	Responsabilidade	Tecnologia
Aplicação	Janela, overlays, estado visível, preferências	Tauri 2 com interface local
Núcleo	Sessões, captura, orquestração, inserção de texto, política de modelos	Rust
Motor	Reconhecimento, tradução, síntese, diarização	Processos Python isolados
Adaptadores	Um por família de modelos, com licença e contrato próprios	Processos separados
Catálogo	Manifestos, licenças, hashes, estado de validação	Ficheiros versionados

Regras de isolamento: um adaptador que falha não derruba a sessão; o núcleo aplica tempo limite e substitui o motor; nenhum adaptador escreve diretamente em dados do utilizador; e cada adaptador declara a sua licença no manifesto, para que a fronteira de distribuição seja auditável.

57. Protocolo entre núcleo e motores

O transporte é JSON por linha sobre pipes do processo, com identificador de pedido, operação, versão de protocolo e resposta ou erro estruturado. Operações atuais: saúde, aquecimento, tradução por bloco, streaming de texto e dobragem.

Contrato: campos obrigatórios validados dos dois lados; versão de protocolo negociada no arranque; erro sempre com código e mensagem legível; nenhum adaptador pode enviar áudio para a rede; e o núcleo recusa um adaptador que declare uma licença incompatível com o perfil de distribuição ativo. Uma alteração incompatível do protocolo exige versão nova e adaptadores atualizados, com teste de contrato no CI.

58. Pipeline de áudio, latência e adaptação

Caminho do áudio: captura do dispositivo, verificação de formato, deteção de atividade, reconhecimento incremental, estabilização de texto, tradução por unidades semânticas, síntese ou legendas, e saída para o dispositivo, para o campo ativo ou para ficheiro.

A latência é medida em quatro pontos distintos, porque somar tudo num número esconde o gargalo:

Medição	Início	Fim
Reconhecimento	Início de fala	Primeiro resultado parcial
Tradução	Texto estável	Texto traduzido
Voz	Texto traduzido	Primeiro áudio sintetizado
Total	Início de fala	Primeiro áudio audível

Para cada modo mede-se também a latência depois de a conversa estar estabelecida, e publicam-se P50 e P95 com as condições de teste: hardware, modelos, quantização, threads e duração da sessão.

Perfil	Objetivo	O que privilegia
Baixa latência	Primeiro áudio cedo, qualidade de voz menor	Modo quase-tempo-real em máquinas modestas
Equilibrado	2,5 s até ao primeiro áudio traduzido, como objetivo inicial	Melhor relação entre atraso e qualidade
Alta qualidade	Latência maior, identidade vocal e naturalidade primeiro	Gravação, dobragem e leitura

Os 2,5 segundos são um objetivo do perfil equilibrado, não uma garantia universal nem uma promessa de release. Se não forem atingidos, o produto apresenta o valor real e nomeia o gargalo em vez de esconder o atraso. A identidade vocal e a qualidade da tradução não se sacrificam para cumprir um tempo: nesse caso muda-se de perfil e diz-se que mudou.

O controlador adaptativo reduz unidades, muda o modo de processamento ou desativa a voz quando o atraso acumula, e diz ao utilizador o que mudou.

59. Hardware, backends e perfis

Perfil	Hardware típico	O que se espera	O que não se promete
Mínimo	4 núcleos, 8 GB, sem GPU utilizável	Reconhecimento e tradução funcionam; voz neutra leve	Clonagem em tempo real
Equilibrado	8 núcleos, 16 GB, iGPU	Reconhecimento rápido, tradução local, clonagem em blocos	Latência de conversa
Alto	16 núcleos, 32 GB, GPU dedicada	Clonagem com boa qualidade, quase-tempo-real	Paridade com estúdio
Workstation	64 GB e GPU de grande memória	Qualidade máxima e sessões longas	Suporte universal

A seleção não usa regras simplistas. Cada perfil é uma combinação medida de memória livre, instruções do processador, backend disponível e resultado do benchmark. Um computador com 8 GB mas com GPU utilizável não é tratado como o perfil mínimo.

60. Extensibilidade: CLI, API, SDK e plugins

Superfície	Estado	Contrato
CLI	Implementada	Comandos estáveis, saída legível e código de saída definido
API local	Existe servidor em loopback com token	Rota documentada, sem promessa de estabilidade antes da v1.x
SDK	Planeado	Contratos versionados e testes de compatibilidade
Plugins	Planeado	Permissões granulares e níveis oficial, comunitário e experimental
MCP	Planeado	Opcional, com autorização explícita por ferramenta

Regra: uma capacidade só chega à API depois de existir na aplicação. A aplicação nunca depende de uma interface que o utilizador não vê, e nenhuma superfície de automação recebe acesso a perfis de voz sem autorização explícita.

PARTE IX · PRIVACIDADE, SEGURANÇA E LEGISLAÇÃO

61. Privacidade local-first

Dado	Onde vive	Por defeito
Áudio capturado	Memória da sessão	Não é guardado sem pedido
Amostra de referência de voz	Pasta de dados do utilizador	Guardada só com consentimento
Embeddings e prompts de voz	Pasta de dados do utilizador	Derivados e apagáveis
Transcrições	Pasta de dados do utilizador	Guardadas só com histórico ativo
Traduções	Sessão e histórico opcional	Apagáveis
Gravações de reunião	Pasta de dados do utilizador	Só com aviso e opt-in
Caches	Pasta de dados do utilizador	Apagáveis em conjunto
Registos de diagnóstico	Pasta de dados do utilizador	Sem áudio por omissão
Relatórios de erro	Nunca enviados automaticamente	Envio manual e revisto
Analytics e telemetria	Não existem	—

A única chamada externa permitida é a verificação da última release estável, e não transporta áudio, conteúdo, identificadores de utilizador nem telemetria. Nenhum áudio sai da máquina em modo local. Nenhum dado é recolhido para treino.

62. Dados pessoais e biométricos

Um embedding de voz não é automaticamente dado biométrico de categoria especial em todos os contextos: depende da finalidade e do tratamento. Uma representação usada para identificar uma pessoa é tratada como dado biométrico; uma representação usada para gerar áudio na voz dessa pessoa é, no mínimo, dado pessoal e exige controlo reforçado. Esta distinção é técnica e não substitui avaliação jurídica.

Medidas que o Parlo adota independentemente da qualificação: base legal assente em consentimento para o perfil de voz; finalidade declarada e limitada; minimização (não guardar áudio se bastar a representação derivada, quando o motor o permitir); prazo de conservação definido pelo utilizador; eliminação completa; portabilidade por exportação; e nenhuma partilha com terceiros.

63. Regulamento Europeu da IA e Artigo 50

O Parlo é um projeto open-source, gratuito e local. Isso reduz exposição, mas não elimina automaticamente obrigações: a isenção para sistemas de código aberto não cobre todos os casos, e as obrigações de transparência do Artigo 50 aplicam-se a partir de 2 de agosto de 2026. As datas e a interpretação devem ser confirmadas com aconselhamento jurídico antes de qualquer declaração pública de conformidade.

Obrigação	A quem se aplica	O que o Parlo faz
Informar que se interage com um sistema de IA	Fornecedor que coloca o sistema no mercado	A aplicação diz que a voz é sintetizada, sempre que o for
Marcar conteúdo sintético de forma legível por máquina	Fornecedor de sistemas generativos	Metadados de origem e marca de água quando tecnicamente viável; documentado o que falta
Divulgar deepfakes	Responsável pela utilização que publica o conteúdo	O produto avisa e regista; a divulgação é responsabilidade de quem publica
Transparência sobre limitações	Fornecedor	Documentação de limitações por modo e por idioma

Regras de produto: a saída sintetizada é sempre identificada na interface e nos ficheiros exportados; o utilizador recebe um aviso claro de que a divulgação de conteúdo que imita uma pessoa pode ser exigida por lei; e nenhuma funcionalidade de voz é apresentada como indistinguível de uma gravação real. Não se afirma que toda a tradução de voz é um deepfake: a classificação depende do contexto e da forma como o conteúdo é apresentado.

64. Segurança e cadeia de fornecimento

- Downloads apenas por HTTPS de origem declarada no manifesto, com hash verificado antes do uso.
- Nenhum modelo executado a partir de um caminho arbitrário sem verificação de integridade.
- Modelos tratados como dados não fidedignos: processamento isolado, sem acesso a ficheiros do utilizador.
- Instaladores assinados quando existir certificado; caso contrário, publicação de hashes e instruções de verificação.
- Dependências fixadas, SBOM por release e revisão de novas dependências antes de entrarem no núcleo.
- Nenhuma credencial no repositório; verificação de segredos no CI.
- Relato de vulnerabilidades com prazo de resposta declarado em `SECURITY.md`.

65. Reuniões: consentimento e contexto

Gravar uma reunião exige aviso e, em muitos contextos, consentimento dos participantes. O Parlo não decide isso pelo utilizador: mostra um aviso claro antes da primeira gravação, exige confirmação por sessão, oferece o modo «sem guardar áudio» e permite apagar uma sessão inteira com os seus artefactos. Nenhuma reunião é enviada para fora da máquina, nem resumida por um serviço externo.

PARTE X · REUNIÕES

66. Parlo Meeting: Lite, Live e Chat

Três entregas distintas, com dependências próprias. Durante uma reunião, o Parlo deve ser quase invisível quando funciona e imediatamente claro quando precisa de atenção.

Entrega	O que faz	Dependências	Estado
Meeting Lite	Importar gravação e produzir transcrição com timestamps, falantes corrigíveis e exportação	Reconhecimento, diarização offline, modelo de dados	Planeado
Meeting Live	Transcrever em direto com microfone e áudio do sistema	Captura multifonte, diarização, avisos, estabilidade	Planeado
Meeting Chat	Perguntar a reuniões autorizadas com citações e timestamps	Indexação local, abstenção, proveniência	Planeado

Requisitos transversais: diarização sem identificação nominal automática; associação falante-pessoa apenas manual; resumo e tarefas derivados da transcrição com citação; exportação em Markdown, SRT, VTT e JSON; e eliminação que remove áudio, transcrição, índices e caches. Nenhuma análise pós-reunião pode bloquear a transcrição em direto.

PARTE XI · QUALIDADE, ROADMAP E FASES

67. Lições de Handy, VoiceStudio e Wispr Flow

Projeto	O que faz bem	O que o Parlo aprende	O que não copia
Handy	Fluxo simples, atalho, VAD, escolha entre Whisper e Parakeet, inserção no campo ativo	Clareza de fluxo e custo baixo de instalação	A ausência de gestão de modelos e de voz
VoiceStudio	Gestor de modelos extensível, deteção de dispositivo, instalação sob confirmação	Catálogo amplo e instalação explícita	A exposição da complexidade ao utilizador
Wispr Flow	Ditado com tradução e experiência polida	Barra flutuante discreta e inserção fiável	Dependência de serviço externo

Nenhuma destas comparações afirma superioridade. O Parlo pode ser melhor na combinação de voz própria, execução local e governação de licenças; e pode ser pior em maturidade, suporte de plataformas e polimento durante muito tempo.

68. Roadmap incremental

Cada release é instalável, útil por si só e medida. Os números de versão são sequenciais a partir da última tag publicada e não correspondem a marcos internos.

Release	Nome	O que o utilizador passa a poder fazer	Gate de saída
Próxima	Tradução fechada	Traduzir PT↔EN sem dependência AGPL, com par aprovado	G-MT: nenhum par declarado sem corpus representativo
Seguinte	Voz própria	Criar Voice Profile e ouvir uma tradução na própria voz	G-Voice: consentimento, qualidade e identidade medidos
Seguinte	Modelos	Instalar, trocar e remover modelos com licença e hash visíveis	G-Models
Seguinte	Automático	Auto Select e fallback a funcionar em todas as tarefas	G-Select
Seguinte	Reuniões Lite	Importar gravação e obter transcrição com falantes	G-Meeting-Lite
Depois	Live	Conversa bidirecional com voz	G-Live
Depois	Plataforma	API estável, SDK e plugins	G-Platform

Regra: as releases só avançam quando os gates fecham. Não há calendário neste documento, e uma release pode demorar o tempo que o gate exigir.

69. Fases de execução e critérios de conclusão

Fase	Trabalho	Critério de conclusão
1	Resolver a tradução EN→PT	Checkpoint redistribuível, licença confirmada, conjunto de 100 frases com números e negações acima do limiar, sem regressões
2	Remover o Argos do núcleo	Nenhuma dependência AGPL no caminho principal; catálogo sem artefactos não verificados
3	Voice Profile e consentimento	Criar, ouvir, exportar e apagar um perfil; registo de consentimento completo
4	Integrar clonadores	Qwen3-TTS Base e Chatterbox PT-PT medidos em CPU e GPU, com identidade e latência registadas
5	Proteção de dados vocais	Encriptação opcional, eliminação total verificada, nenhuma escrita fora da pasta de dados
6	Manifestos completos	Todos os campos da secção 28 preenchidos para cada candidato
7	Model Hub	Instalar, atualizar, remover, verificar hash e explicar escolha
8	Auto Select e fallback	Cadeias da secção 36 aplicadas, com aviso e registo
9	Benchmarks internos	Corpus versionado, execução reproduzível e resultados publicados com condições
10	Documentação e transparência	Privacidade, licenças, voz, modelos e limitações publicados e coerentes com o código

As fases 1 a 3 têm precedência. A clonagem antes da voz neutra é ordem de produto, não preferência: sem perfil de voz e sem tradução fiável, a clonagem amplifica um erro em vez de criar valor.

70. Definição de concluída e regras de corte

Uma release está concluída quando: instala em máquina limpa e atualiza sobre a anterior; o rollback funciona; o benchmark do corpus está atualizado com hardware e versões; a matriz de licenças foi revista para tudo o que a release inclui; a auditoria de rede mostra zero ligações externas além da consulta ao catálogo; o changelog declara limitações conhecidas; a acessibilidade mínima foi verificada nos fluxos principais; cada funcionalidade está classificada como experimental, preview, beta ou estável; e o instalador está dentro do orçamento de tamanho ou o desvio está explicado.

Validação com utilizadores externos é um gate próprio, não uma condição de todo o desenvolvimento. Enquanto não existirem testadores reais, os testes internos, funcionais e de acessibilidade podem avançar, e o produto nunca anuncia resultados de usabilidade que não foram medidos. O gate de usabilidade fica registado como não realizado, não como aprovado.

Regras de corte: se o gate falha, a release não sai e a anterior continua a ser a estável; se um modelo não passa, a release sai sem ele com a alternativa já aprovada; trabalho fora do objetivo entra apenas se não atrasar o gate; e o roadmap é revisto com dados medidos, não com expectativas.

71. Barra competitiva

Dimensão	Handy	VoiceStudio	Objetivo do Parlo
Simplicidade	Forte	Amplo, com gestor de modelos	Automático por omissão
Voz própria	Não é o foco	Ferramentas de voz separadas	Caminho principal
PT-PT	Transcrição	Cobertura variável	Variante explícita, sem promessas
Seleção de modelos	Limitada	Manual	Auto Select com fallback
Licenças	Do projeto	Notas por engine	Manifesto por artefacto e gate automático
Privacidade	Local	Local com downloads	Local por omissão e auditoria de rede
Extensibilidade	Moderada	Alta	Alta, com contratos versionados

PARTE XII · OPEN SOURCE, DISTRIBUIÇÃO E GOVERNANÇA

72. Repositório e ficheiros obrigatórios

Ficheiro	Estado	Função
`README.md`	Existe	Produto, instalação, estado real, secção de licenciamento
`LICENSE`	Existe	Apache-2.0 do código original
`NOTICE`	Existe	Aviso de atribuição exigido pela Apache-2.0
`LICENSES.md`	Existe, gerado	Índice por módulo, licença de código, pesos e vozes
`THIRD_PARTY_NOTICES.md`	Existe, gerado	Avisos de terceiros
`licenses/`	Existe	Textos integrais preservados, incluindo MIT histórico
`CONTRIBUTING.md`	Existe	Regras de contribuição e proveniência
`CODE_OF_CONDUCT.md`	Existe	Conduta
`SECURITY.md`	Existe	Relato de vulnerabilidades
`SUPPORT.md`	Existe	Onde pedir ajuda
`GOVERNANCE.md`	Existe	Como decisões são tomadas
`ACCEPTABLE_USE.md`	Existe	Uso aceitável, incluindo voz
`docs/PRIVACY.md`	Existe, a reforçar	Dados, retenção e eliminação
`docs/MODEL_LICENSES.md`	Existe	Licenças por artefacto de modelo
`catalog/models.json`	Existe	Catálogo com hash, licença e estado
Documento de voz	Em falta	Política de voz e consentimento, pública
Política de modelos externos	Em falta	Como instalar modelos fora do catálogo
`docs/COMPLIANCE.md`	Existe	Checklist interna: licenças, voz, privacidade, Artigo 50, distribuição e revisão por release

O README declara o estado real, diz o que não funciona e liga para `LICENSES.md`. Nenhum badge afirma conformidade, suporte ou desempenho que não exista.

73. Licença do código, DCO e contribuições

O código original está sob Apache-2.0 desde que a titularidade do histórico foi confirmada. As releases até v0.1.7 mantêm o texto MIT com que foram publicadas, preservado em `licenses/`. Não há relicenciamento retroativo.

Regra	Decisão
Assinatura de commits	DCO, verificado no CI
Transferência de direitos	Não exigida
Proveniência	Contribuições de terceiros identificadas e licenciadas de forma compatível
Código sem proveniência	Recusado
Contribuições empresariais	Aceites nas mesmas condições
Alteração futura de licença	Só com acordo dos titulares e registo público

74. Releases, artefactos e avisos

Cada arquivo de release inclui `LICENSE`, `NOTICE`, `THIRD_PARTY_NOTICES.md`, SBOM CycloneDX, o índice de licenças, hashes dos artefactos e a lista de componentes com versões. Não inclui pesos de modelos, vozes, runtimes GPL nem amostras de áudio.

Regra	Efeito
Release só com o gate verde	Nenhuma publicação com licença pendente
Notas de release	O que a versão faz, o que não faz, limitações e números medidos
Uma release por lote de trabalho	Sem publicação em série para o mesmo conjunto de alterações
Verificação de atualização na aplicação	Lê a última release estável e mostra as notas antes de instalar
Release antiga com problema	Não é reescrita nem apagada; é corrigida por documentação e, quando aplicável, pela disponibilização do código correspondente

75. Transparência na aplicação

Uma área chamada «Licenças e código aberto» apresenta, por componente: nome, versão, licença, ligação para a licença original, atribuição exigida e se é obrigatório, opcional ou externo. Antes de instalar um componente com licença própria, aparece uma explicação curta do que essa licença implica, em linguagem simples. A área inclui também os modelos instalados, com a licença de cada um, e o que foi apagado quando o utilizador remove um modelo.

Regra de equilíbrio: a informação está a dois cliques e nunca interrompe o fluxo normal. Avisos jurídicos longos ficam na documentação; a aplicação diz o essencial numa frase.

76. Governação

Decisões de arquitetura e de licenciamento são registadas com data, contexto e consequências. Alterações que afetem licenças, privacidade ou direitos de voz exigem revisão explícita e não entram por rotina. O projeto mantém um registo de decisões abertas na secção 80 e um registo de alterações por versão do plano.

PARTE XIII · DECISÕES E RISCOS

77. Decisões fechadas

#	Decisão	Consequência
1	Voz própria é o caminho principal	Clonagem antes de voz neutra; fallback explícito
2	Nenhum modelo é default sem gate interno	Fim das promoções por leitura de model card
3	Argos fora do núcleo e das dependências obrigatórias	Tradução por NMT aprovado por par
4	Piper opcional e externo	Núcleo sem GPL; vozes com licença própria
5	Pesos e vozes nunca nos arquivos de release	Catálogo com hash e licença por artefacto
6	Licença Apache-2.0 no código original	`LICENSE` e `NOTICE`; MIT histórico preservado
7	DCO sem transferência de direitos	Contribuições verificadas no CI
8	Local-first sem telemetria	A consulta ao catálogo é a única chamada externa
9	Model Hub decide, utilizador não compara	Interface com Automático e override avançado
10	Nenhuma capacidade anunciada antes de medida	README e notas limitados ao real
11	Orquestração determinística, sem meta-modelo	Regras, manifestos e medições explicam cada escolha
12	Sem benchmarks pesados na máquina do utilizador	Níveis A, B e C separados
13	Aplicação sem pesos, com orçamento próprio	Objetivo de 100 MB, limite de referência de 150 MB
14	Biblioteca independente em `parlo-models`	Catálogo e pesos evoluem sem reinstalar a aplicação
15	Manifestos assinados com Ed25519	Chave pública na aplicação; privada fora do repositório
16	Sem Authenticode nesta fase	Hashes e instruções, sem os apresentar como assinatura
17	Clonagem da própria voz e de terceiros autorizados	Declaração obrigatória; engano proibido
18	Corpus de avaliação original sob CC0-1.0	Texto próprio, sem dados privados de terceiros
19	Latência publicada em P50 e P95 por perfil	2,5 s é objetivo do perfil equilibrado, não garantia
20	Sem parecer jurídico nesta fase	Checklist interna de conformidade revista por release

78. Decisões que o Parlo toma automaticamente

- Qual o motor de reconhecimento, tradução e voz para a tarefa, idioma, variante e hardware.
- Quando degradar para voz neutra ou para texto, e como o dizer.
- Que modelo descarregar quando o utilizador escolhe uma capacidade e não um modelo.
- Como dividir unidades de tradução e quando emitir voz.
- Que perfil de voz é compatível com que motor e que representação derivar.
- Quando recusar um artefacto por licença, hash ou incompatibilidade.
- Quando mudar de motor, entre segmentos, respeitando permanência mínima e histerese.
- Quando invalidar um resultado de cache e repetir a validação técnica.
- Quando promover um modelo de compatível a recomendado, depois de validação no dispositivo.

79. Decisões pendentes de teste interno

#	Pendente	Como fecha
1	Checkpoint EN→PT que traduza bem	Conjunto de 100 frases, licença confirmada, limiar de fidelidade
2	Clonador para PT-PT em CPU	Identidade, inteligibilidade e latência medidas
3	Melhor clonador em GPU	Comparação cega com o mesmo perfil e corpus
4	Motor de reconhecimento por perfil de hardware	Benchmark nos perfis da secção 59
5	Diarização utilizável em reuniões	Taxa de erro de segmentação em gravações reais
6	Viabilidade de marcador de conteúdo sintético	Prova técnica por formato de exportação
7	Custo de memória de clonagem em 16 GB	Medição de RSS e VRAM por motor

80. Questões que exigem decisão humana ou validação jurídica

O Parlo é um projeto pessoal, gratuito, open-source e público, sem venda, subscrição, publicidade ou rendimento associado. Nesta fase não há parecer jurídico contratado e a ausência dele não bloqueia desenvolvimento nem publicação. Também não é apresentado como conformidade jurídica: o projeto cumpre o que consegue verificar e identifica o que exige interpretação.

Obrigação ou questão	Estado no projeto	O que falta
Licenças de código, dependências e pesos	Verificadas por artefacto, com gate automático	Manter atualizado a cada dependência nova
Avisos e atribuições	`NOTICE`, avisos de terceiros e índice gerados	Revisão manual antes de cada release
Consentimento de voz	Registo local com finalidade, âmbito e data	Texto final da política de voz
Dados vocais e retenção	Local, apagável, sem envio	Confirmar cada finalidade nova
Regulamento Europeu da IA, Artigo 50	Marcação e divulgação identificadas por interveniente	Forma técnica de marcação por formato
RGPD	Minimização, finalidade e eliminação implementadas	Qualificação de embeddings por finalidade

Três pontos ficam explicitamente como interpretação jurídica, sem bloquear o trabalho: a qualificação de obra combinada ao distribuir um adaptador GPL ao lado do núcleo; a forma de divulgação de conteúdo sintético que satisfaça o Artigo 50; e o tratamento de representações vocais como dado biométrico em cada finalidade concreta.

Consulta jurídica só se justifica quando existir dúvida material e concreta que não se resolva com documentação oficial, licença aplicável ou análise técnica razoável — por exemplo, uma distribuição que combine binários copyleft com o núcleo, ou um pedido de utilização comercial que dependa dessa qualificação. O acompanhamento fica numa checklist interna de conformidade, revista a cada release.

81. Riscos por severidade

Nível	Risco	Mitigação
Crítico	Clonagem de voz sem consentimento	Registo obrigatório, eliminação total, uso aceitável, recusa de conteúdo enganoso
Crítico	Tradução EN→PT sem modelo	Nenhum par declarado até gate; pivô assinalado
Alto	Dependência AGPL no núcleo	Saída do Argos e gate por âmbito
Alto	Promessa de identidade vocal que o motor não cumpre	Medição por motor e aviso explícito
Alto	Distribuição de pesos sem licença	Catálogo com estado de verificação e bloqueio de download

Nível	Risco	Mitigação
Médio	Complexidade de Model Hub atrasar o produto	Fases 6 a 8 em sequência, sem antecipar interface
Médio	Orquestrador a oscilar entre motores	Permanência mínima, histerese, circuit breaker e limite de tentativas
Médio	Benchmark a competir com o trabalho do utilizador	Nível B limitado a segundos e interrompido sob pressão de memória
Médio	Cache a reutilizar resultados de outro ambiente	Chave com modelo, hash, runtime, quantização, hardware e versão do benchmark
Baixo	Manifesto desatualizado a esconder uma limitação	Versão de manifesto no catálogo e validação no CI
Alto	Aplicação a crescer com o catálogo	Pesos fora do instalador; regra de dimensionamento na secção 44
Médio	Modelo atualizado a quebrar o que funcionava	Instalação ao lado, validação antes da troca e rollback
Médio	Dependências partilhadas apagadas com um modelo	Remoção protege referências de outros modelos
Médio	Importação externa a executar código	Nenhum código do pacote corre; importados fora do automático
Médio	Desempenho em hardware modesto	Perfis medidos e degradação explícita
Médio	Deriva entre README, catálogo e notas de release	Gate de coerência antes de publicar
Baixo	Duplicação de documentação de licenças	Índice gerado a partir de uma fonte única

82. Checklist final antes da primeira release

- Tradução PT↔EN com par aprovado e licença fechada; nenhuma dependência AGPL no núcleo.
- Voice Profile com consentimento, pré-visualização e eliminação verificada.
- Pelo menos um clonador medido em PT-PT, com identidade e latência publicadas.
- Model Hub a instalar, verificar, trocar e remover, com licença visível.
- Auto Select e fallback aplicados com aviso e registo.
- Benchmarks reproduzíveis, com hardware, versões, corpus e data.
- `LICENSE`, `NOTICE`, avisos, SBOM, índice e hashes nos artefactos.
- Área «Licenças e código aberto» na aplicação.
- `docs/PRIVACY.md` e política de voz publicados e coerentes com o código.
- Auditoria de rede sem ligações externas durante a sessão.
- Acessibilidade verificada nos fluxos principais.
- Instalação limpa, atualização e rollback testados.
- Notas de release que digam o que não funciona.
- Orquestrador a passar os critérios de aceitação da secção 42, com testes sem modelos reais e um modelo real validado no dispositivo.
- Manifesto de cada modelo candidato com evidência declarada, validada e limitações conhecidas.
- Instalador sem pesos; biblioteca a crescer sem alterar o tamanho da instalação.
- Catálogo atualizável sem reinstalar a aplicação, com descoberta que não descarrega.
- Instalar, substituir e remover modelos individualmente, sem tocar em perfis de voz nem em preferências.

- Remoção de um modelo a proteger dependências partilhadas e a oferecer alternativa quando está em uso.

APÊNDICES

A. Factos por componente

Verificação documental realizada em 1 de novembro de 2026. Cartões e repositórios mudam; antes de distribuir, fixar commit ou checkpoint, descarregar a licença exata e registar o hash.

Componente	Função	Licença do código	Licença de pesos ou vozes	PT-PT	Estado
sherpa-onnx 2.0.1	Runtime de reconhecimento	Apache-2.0	Não aplicável	Sim	Em uso
faster-whisper 1.2.1	Runtime Whisper	MIT	Não aplicável	Sim	Em uso
CTranslate2	Runtime de tradução e de Whisper	MIT	Não aplicável	Sim	Aceite
Parakeet TDT 0.6B v3	Reconhecimento	Apache-2.0	CC-BY-4.0	Sim	Recomendado
Whisper large-v3-turbo	Reconhecimento	MIT	MIT	Sim	Compatível
Qwen3-ASR 0.6B	Reconhecimento	Apache-2.0	Apache-2.0	Por confirmar	Experimental
Argos Translate 1.11.0	Tradução	MIT	Pacotes por verificar	Sim	Em revisão
MiniSBD	Segmentação de frases	AGPLv3	Não aplicável	Não aplicável	Risco: sair do núcleo
OPUS-MT ROMANCE-en	Tradução PT→EN	MIT (Opus-MT)	Apache-2.0	Sim	Candidato
OPUS-MT tc-big-en-pt	Tradução EN→PT	MIT (Opus-MT)	CC-BY-4.0	Falhou	Por resolver
M2M100 418M	Tradução	MIT	Por confirmar	Por medir	Candidato
Qwen3-TTS 0.6B Base	Clonagem	Apache-2.0	Apache-2.0	Por medir	Candidato prioritário
Qwen3-TTS 1.7B Base	Clonagem	Apache-2.0	Apache-2.0	Por medir	Candidato
Qwen3-TTS 1.7B CustomVoice	Voz predefinida	Apache-2.0	Apache-2.0	Por medir	Compatível, não clona
Qwen3-TTS 1.7B VoiceDesign	Desenho de voz	Apache-2.0	Apache-2.0	Por medir	Experimental
Chatterbox Multilingual pt-PT	Clonagem PT-PT	MIT	MIT	Sim	Candidato prioritário
Chatterbox Multilingual pt-BR	Clonagem pt-BR	MIT	MIT	Não	Catálogo separado
VoxCPM2 e VoxCPM 0.5B	Clonagem	Apache-2.0	Apache-2.0	Por medir	Experimental
Kokoro 82M	Voz neutra	Apache-2.0	Apache-2.0	Não	Compatível
Piper / rhasspy voices	Voz neutra	piper1-gpl GPL-3.0-or-later	MIT no repositório de vozes	Sim	Externo
espeak-ng	Fonemização do Piper	GPL-3.0	Não aplicável	Sim	Externo
F5-TTS	Clonagem	MIT	CC-BY-NC	Por medir	Bloqueado
XTTS-v2	Clonagem	Coqui Public Model License	Não comercial	Sim	Bloqueado
NLLB-200	Tradução	MIT	CC-BY-NC-4.0	Sim	Bloqueado
SeamlessM4T v2	Tradução e voz	MIT	CC-BY-NC-4.0	Sim	Bloqueado

Componente	Função	Licença do código	Licença de pesos ou vozes	PT-PT	Estado
Silero VAD	Deteção de voz	MIT	Não aplicável	Não aplicável	Recomendado
pyannote	Diarização	MIT (código)	Condições de acesso	Sim	Candidato condicionado
PyInstaller	Empacotamento	GPL com exceção de uso	Não aplicável	Não aplicável	Aceite com aviso

B. Glossário operacional

- **Voice Clone First** — política que tenta primeiro a voz autorizada da pessoa e trata a voz neutra como recurso.
- **Voice Profile** — recurso local com identidade, amostra de referência, representações por motor e consentimento.
- **Representação** — artefacto derivado de um perfil para um motor específico, como embedding ou prompt de voz.
- **Clonagem** — síntese com a identidade de uma pessoa autorizada, a partir de amostra.
- **Desenho de voz** — criação de uma voz por descrição, sem amostra de pessoa real.
- **Voz neutra** — voz de catálogo sem identidade do utilizador.
- **Model Hub** — componente que conhece, instala, verifica e explica modelos.
- **Auto Select** — algoritmo determinístico que escolhe o modelo por tarefa, idioma, hardware e licença.
- **Gate** — condição objetiva que uma release ou um modelo tem de cumprir para avançar.
- **Recommodado, compatível, experimental, bloqueado, externo** — estados operacionais do catálogo.
- **Par validado** — par de línguas com avaliação humana e corpus, não apenas cobertura declarada.
- **Pivô** — tradução por uma língua intermédia, sempre assinalada.
- **Declaração de consentimento** — registo local com finalidade, âmbito, versão do aviso e data.
- **Fronteira de licença** — separação técnica entre núcleo permissivo e componentes com outra licença; não é, por si só, conclusão jurídica.
- **PIMO** — orquestrador que filtra, avalia, seleciona, compõe e monitoriza modelos com regras determinísticas.
- **Níveis A, B e C** — avaliação estática por manifesto, validação técnica no dispositivo e avaliação aprofundada de qualidade.
- **Histerese** — exigência de que a alternativa seja claramente melhor para justificar troca de motor.
- **Circuit breaker** — retirada temporária de um motor da seleção após falhas repetidas.
- **Chave de cache** — combinação de modelo, hash, runtime, quantização, hardware e versão do benchmark que valida um resultado.

C. Fontes primárias

- Handy — projeto e documentação de modelos: https://github.com/cjpais/Handy
- VoiceStudio — catálogo de engines: https://github.com/debpalash/VoiceStudio
- sherpa-onnx — https://github.com/k2-fsa/sherpa-onnx
- faster-whisper — https://github.com/SYSTRAN/faster-whisper
- CTranslate2 — https://github.com/OpenNMT/CTranslate2
- Opus-MT — https://github.com/Helsinki-NLP/Opus-MT

- Argos Translate — https://github.com/argosopentech/argos-translate
- MiniSBD — https://github.com/LibreTranslate/MiniSBD
- Qwen3-ASR — https://github.com/QwenLM/Qwen3-ASR
- Qwen3-TTS — https://github.com/QwenLM/Qwen3-TTS
- Chatterbox — https://github.com/resemble-ai/chatterbox
- Chatterbox pt-PT — https://huggingface.co/ResembleAI/Chatterbox-Multilingual-pt-pt
- Piper voices — https://huggingface.co/rhasspy/piper-voices
- Piper runtime — https://github.com/OHF-Voice/piper1-gpl
- espeak-ng — https://github.com/espeak-ng/espeak-ng
- Kokoro — https://huggingface.co/hexgrad/Kokoro-82M
- VoxCPM — https://huggingface.co/openbmb/VoxCPM2
- Silero VAD — https://github.com/snakers4/silero-vad
- pyannote — https://github.com/pyannote/pyannote-audio
- Apache-2.0 — https://www.apache.org/licenses/LICENSE-2.0
- MIT — https://opensource.org/license/mit
- Regulamento Europeu da IA, Artigo 50 — https://eur-lex.europa.eu/eli/reg/2024/1689/oj

D. Registo de alterações da v12.3

D.1 Resumo face à v12.2

Área	v12.2	v12.3
Estrutura	Doze partes com secções 1 a 58, algumas fora de ordem e um subtítulo de interface dentro da secção errada	Treze partes, secções 1 a 82 em ordem, sem duplicações; a voz, a orquestração e a biblioteca ganham partes próprias
Biblioteca	Modelos descritos apenas como entradas de catálogo, sem ciclo de vida próprio	Parte VII: duas camadas, contratos, catálogo evolutivo, compatibilidade, instalar e remover, armazenamento, curadoria, novidades, importação, distribuição segura, ciclos independentes e dois modos
Orientações do autor	Dezasseis pontos em aberto sobre tamanho, catálogo, assinatura, Piper, Argos, corpus e jurídico	Fixados na Parte VII e nas secções 77 a 82: orçamento de 100 MB, `parlo-models`, Ed25519, Piper fora do instalador, Argos fora do núcleo, corpus CC0-1.0, sem parecer jurídico nesta fase
Orquestração	Model Hub e Auto Select em cinco secções, sem ciclo de avaliação nem monitorização	Parte VI com PIMO: manifesto e níveis de evidência, filtragem, perfil de dispositivo, avaliação em três níveis, benchmarks por tarefa, seleção multicritério, composição, monitorização, fallback, ciclo de vida, cache, testes, critérios de aceitação e fases
Voz	Clonagem descrita dentro da estratégia de TTS	Parte II completa: política, perfil, consentimento, compatibilidade, identidade, papéis da voz neutra
Modelos de clonagem	CustomVoice apresentado como clonagem; Kokoro apresentado como fallback PT-PT	Base 0.6B e 1.7B são clonagem; CustomVoice usa vozes predefinidas; VoiceDesign desenha voz; Kokoro deixa de ser fallback PT-PT
Chatterbox	Tratado como um só candidato	PT-PT como candidato prioritário e PT-BR separado
Tradução	«Decisão fechada» de substituição do Argos	Estado por caminho: PT→EN medido, EN→PT por resolver, Argos em revisão

Área	v12.2	v12.3
Validação	3 amostras corretas citadas como indício forte	Exigido conjunto representativo e avaliação por falante nativo
Hardware	Regra simplista de núcleos e RAM	Perfis medidos e decisão por benchmark, memória, quantização e backend
Perfis de voz	Não endereçada a compatibilidade entre motores	Secção própria com camadas, derivação e eliminação da amostra
Privacidade	Secção genérica	Privacidade por dado, dados biométricos e política de retenção
IA	Referência genérica	Secção sobre o Artigo 50, com obrigações por interveniente e limites
Licenças	Sugestão de que a separação resolve a GPL	Fronteira técnica declarada e questão jurídica isolada
Roadmap	Versões nomeadas com marcos e datas implícitas	Gates e fases por dependência, sem calendário
Benchmarks	Dispersos	Secção única com métricas, gates e regra de publicação

D.2 Decisões técnicas corrigidas pela auditoria

1. Qwen3-TTS 0.6B Base e 1.7B Base são candidatos de clonagem por áudio de referência.

2. Qwen3-TTS CustomVoice não é modelo de clonagem: usa vozes predefinidas.

3. Qwen3-TTS VoiceDesign é desenho de voz, não clonagem.

4. Chatterbox Multilingual PT-PT é candidato prioritário para português europeu; PT-BR é artefacto distinto.

5. Kokoro deixa de ser fallback PT-PT sem prova de cobertura dessa variante.

6. Piper mantém-se opcional, externo e fora dos arquivos de release.

7. Nenhum modelo é declarado vencedor sem teste interno com identidade, inteligibilidade e latência.

8. Perfis de voz não são compatíveis entre motores por omissão; exigem representação derivada.

9. A tradução EN→PT fica formalmente por resolver, com OPUS-MT e M2M100 418M como candidatos.

10. A seleção por hardware deixa de usar regras simplistas e passa a depender de benchmarks.

11. A remoção do Argos do núcleo depende de um par aprovado, não de uma intenção.

12. Um scanner de licenças sem alertas deixa de ser descrito como conformidade.

13. A orquestração é determinística: regras, manifestos e medições, sem um modelo de aprendizado a escolher modelos.

14. A avaliação é progressiva em três níveis, e o nível C nunca corre na máquina do utilizador.

15. A troca de motor obedece a permanência mínima, histerese, circuit breaker e limite de tentativas.

16. Nenhum resultado de benchmark é reutilizado fora do ambiente que o produziu.

17. A aplicação e a biblioteca são camadas separadas, com ciclos de atualização distintos.

18. O instalador não incorpora pesos e o seu tamanho não depende do catálogo.

19. A compatibilidade entre aplicação, catálogo, runtime e modelo é calculada, não prometida.

20. Importar um modelo externo nunca executa código do pacote e nunca o promove a validado.

21. O instalador tem objetivo de 100 MB e limite de referência de 150 MB, sem pesos dentro.

22. O catálogo vive em `parlo-models` e os manifestos são assinados em Ed25519, com a chave pública na aplicação.

23. Sem certificado Windows nesta fase, publicam-se hashes e instruções, sem os apresentar como assinatura.

24. O corpus de avaliação é original, sob CC0-1.0, e cobre PT-PT, PT-BR e EN nos dois sentidos.

25. A conformidade é acompanhada numa checklist interna, revista por release, sem parecer jurídico contratado.

D.3 Questões por resolver

- Checkpoint EN→PT redistribuível que passe o gate de fidelidade.
- Clonador aprovado para PT-PT em CPU e em GPU, com identidade medida.
- Licença dos pesos do M2M100 418M e de outros candidatos de tradução.
- Licença e redistribuição dos pesos de diarização.
- Viabilidade técnica de marcação legível por máquina em cada formato de exportação.
- Qualificação jurídica da distribuição conjunta de adaptadores copyleft.

D.4 Verificação de coerência desta edição

- Numeração contínua de 1 a 82, sem títulos repetidos e com hierarquia de partes correta.
- A Parte VI define o orquestrador sem duplicar o Model Hub, o Auto Select ou o gestor de perfis de voz.
- A prioridade Voice Clone First aparece nas Partes I, II, IV, V, VI, XI e XIII.
- Nenhuma funcionalidade planeada é descrita como implementada; o estado está na secção 1, na secção 20 e no Apêndice E.
- Licenças, modelos e dependências usam as mesmas decisões nas Partes V, XI e XII.
- O roadmap da secção 68 não contradiz as fases da secção 69 nem os gates da secção 32.
- Os critérios de aceitação da secção 42 cobrem as garantias das secções 29 a 40.
- As decisões finais do autor aparecem nas secções 44, 46, 53, 58, 70, 77 e 80 e não contradizem o PIMO nem a biblioteca.
- A Parte VII não duplica o Model Hub nem o PIMO: nomeia módulos com fronteiras e diz qual decide o quê.

E. Mapa das versões

Versão do plano	Conteúdo que fixou
v10.0	Estado real do projeto, perfis de hardware, catálogo revisto, separação entre marcos e tags
v11.0	Roadmap reordenado, Live fora do caminho crítico, licenciamento modular
v12.0	Model Hub, Auto Select, decisão sobre Argos, Piper externo, memorando jurídico
v12.1	Política Voice Clone First e arquitetura de perfil de voz
v12.2	Hierarquia corrigida e verificação documental de Qwen3-TTS Base
v12.3	Parte própria para a voz, matriz de modelos corrigida, tradução por resolver, privacidade e Artigo 50, roadmap por gates; Parte VI com o Parlo Intelligent Model Orchestrator
v12.3 (revisão)	Integração do PIMO: manifesto e evidência, filtragem, perfil de dispositivo, três níveis de avaliação, benchmarks por tarefa, seleção multicritério, composição, monitorização, fallback com proteção de voz, ciclo de vida, cache, testes e fases
v12.3 (revisão 2)	Biblioteca modular: separação aplicação e biblioteca, contratos entre módulos, catálogo evolutivo, compatibilidade entre versões, gestão por modelo, armazenamento, curadoria, avaliação de novidades, importação externa, distribuição assinada e ciclos de atualização independentes
v12.3 (revisão 3)	Decisões finais do autor: orçamento de 100 MB, catálogo em `parlo-models` com Ed25519, Piper e Argos fora do núcleo, corpus CC0-1.0, latência em P50 e P95 por perfil, checklist interna de conformidade em vez de parecer jurídico

Versões do produto e versões do plano são coisas diferentes. A versão do produto avança a partir da última tag publicada; a do plano avança quando este documento é revisto.

F. Regra permanente para o agente de desenvolvimento

O agente do projeto não pede ao utilizador para comparar modelos, executar benchmarks ou escolher entre motores quando o Model Hub consegue decidir. Consulta o catálogo, seleciona o candidato aprovado e continua.

Interrompe apenas quando existir uma decisão humana genuína:

- risco de licença ou jurídico que o código não resolve;
- consentimento de voz ou autorização sobre uma amostra;
- preferência explícita do utilizador que o produto não consegue inferir;
- ausência de qualquer modelo elegível para a tarefa pedida.

Em todos os outros casos, a resposta correta é escolher, medir, registar a razão e dizer em uma frase o que foi escolhido.